

Use Case : les amendements de la XVIIème législature de l’Assemblée Nationale

Objectif : classer automatiquement ces amendements comme **sourcés** ou **non-sourcés** avec ActiveTigger.

Sommaire

Contexte, questions de recherche et données

Annoter les données d’entraînement et fixer son codebook
Entraîner des modèles
Sélectionner un modèle
Évaluer le modèle



ActiveTigger

Résultats
Intérêt et limites de notre cas

Contexte

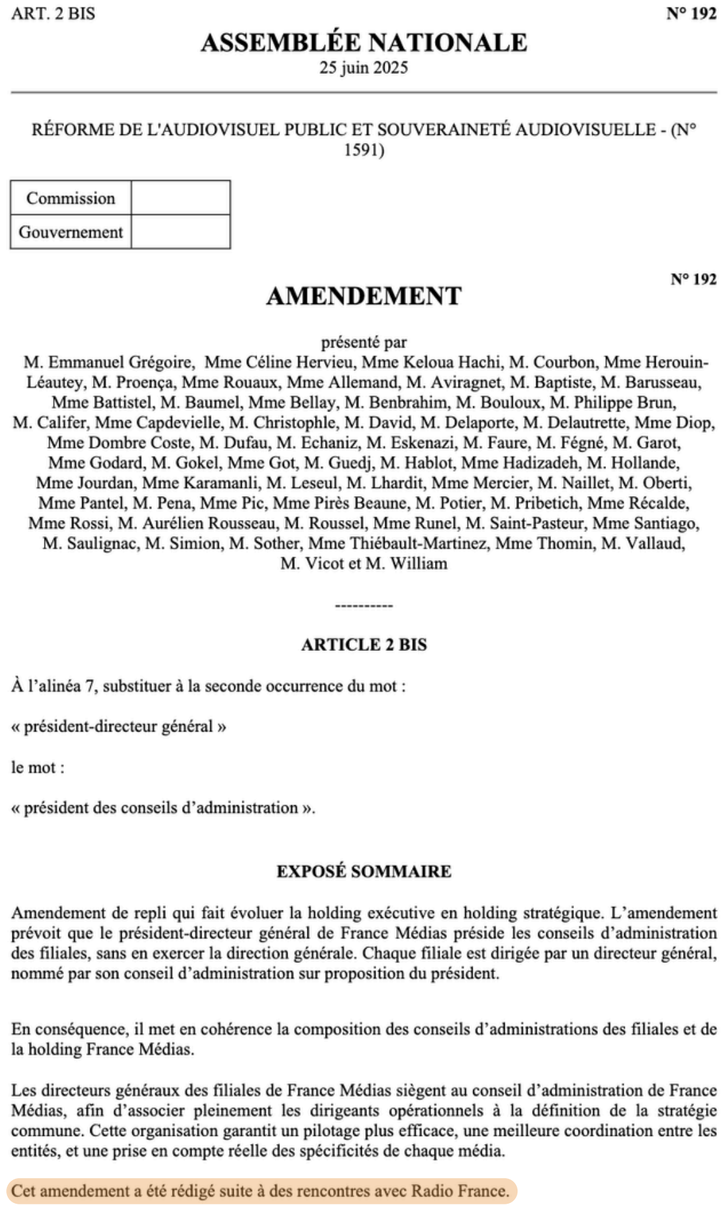
Un amendement résulte de nombreuses interactions.

Certains sont discutés avec ou proposés par un ou plusieurs groupe(s) d'intérêt ("lobbies")

Sourcing des amendements : citer nommément ces groupes et la nature de leur influence sur la soumission d'un amendement donné dans l'exposé des motifs.

➔ "Bonne pratique" promue par un certain nombre de parlementaires mais non obligatoire

(cf. tribune de 322 élus et élues LREM dans Le Monde en octobre 2019)



ART. 2 BIS N° 192

ASSEMBLÉE NATIONALE

25 juin 2025

RÉFORME DE L'AUDIOVISUEL PUBLIC ET SOUVERAINETÉ AUDIOVISUELLE - (N° 1591)

Commission	
Gouvernement	

N° 192

AMENDEMENT

présenté par

M. Emmanuel Grégoire, Mme Céline Hervieu, Mme Keloua Hachi, M. Courbon, Mme Herouin-Léautey, M. Proença, Mme Rouaux, Mme Allemand, M. Aviragnet, M. Baptiste, M. Barusseau, Mme Battistel, M. Baumel, Mme Bellay, M. Benbrahim, M. Bouloux, M. Philippe Brun, M. Califer, Mme Capdevielle, M. Christophle, M. David, M. Delaporte, M. Delautrette, Mme Diop, Mme Dombre Coste, M. Dufau, M. Echaniz, M. Eskenazi, M. Faure, M. Fégné, M. Garot, Mme Godard, M. Gokel, Mme Got, M. Guedj, M. Hablot, Mme Hadizadeh, M. Hollande, Mme Jourdan, Mme Karamanli, M. Leseul, M. Lhardit, Mme Mercier, M. Naillet, M. Oberti, Mme Pantel, M. Pena, Mme Pic, Mme Pirès Beaune, M. Potier, M. Pribetich, Mme Récalde, Mme Rossi, M. Aurélien Rousseau, M. Roussel, Mme Runel, M. Saint-Pasteur, Mme Santiago, M. Saulignac, M. Simion, M. Sother, Mme Thiébault-Martinez, Mme Thomin, M. Vallaud, M. Vicot et M. William

---

ARTICLE 2 BIS

À l'alinéa 7, substituer à la seconde occurrence du mot :

« président-directeur général »

le mot :

« président des conseils d'administration ».

EXPOSÉ SOMMAIRE

Amendement de repli qui fait évoluer la holding exécutive en holding stratégique. L'amendement prévoit que le président-directeur général de France Médias préside les conseils d'administration des filiales, sans en exercer la direction générale. Chaque filiale est dirigée par un directeur général, nommé par son conseil d'administration sur proposition du président.

En conséquence, il met en cohérence la composition des conseils d'administrations des filiales et de la holding France Médias.

Les directeurs généraux des filiales de France Médias siègent au conseil d'administration de France Médias, afin d'associer pleinement les dirigeants opérationnels à la définition de la stratégie commune. Cette organisation garantit un pilotage plus efficace, une meilleure coordination entre les entités, et une prise en compte réelle des spécificités de chaque média.

Cet amendement a été rédigé suite à des rencontres avec Radio France.

sourcing !

Contexte : structure d’un amendement

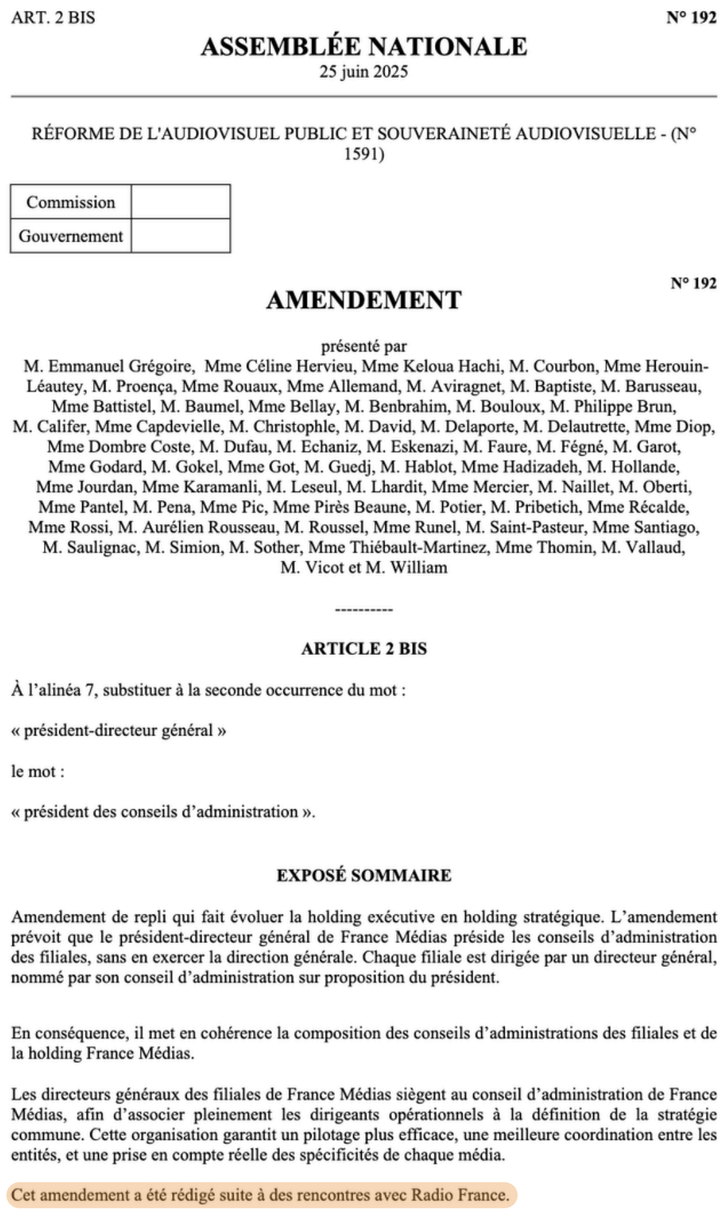
Date, projet de loi, identifiants

Autrices/Auteurs

Substance

Exposé sommaire des motifs

C’est ici que le **sourcing** peut se trouver ⟶



ART. 2 BIS N° 192

ASSEMBLÉE NATIONALE

25 juin 2025

RÉFORME DE L'AUDIOVISUEL PUBLIC ET SOUVERAINETÉ AUDIOVISUELLE - (N° 1591)

Commission	
Gouvernement	

N° 192

AMENDEMENT

présenté par

M. Emmanuel Grégoire, Mme Céline Hervieu, Mme Keloua Hachi, M. Courbon, Mme Herouin-Léautey, M. Proença, Mme Rouaux, Mme Allemand, M. Aviragnet, M. Baptiste, M. Barusseau, Mme Battistel, M. Baumel, Mme Bellay, M. Benbrahim, M. Bouloux, M. Philippe Brun, M. Califer, Mme Capdevielle, M. Christophle, M. David, M. Delaporte, M. Delautrette, Mme Diop, Mme Dombre Coste, M. Dufau, M. Echaniz, M. Eskenazi, M. Faure, M. Fégné, M. Garot, Mme Godard, M. Gokel, Mme Got, M. Guedj, M. Hablot, Mme Hadizadeh, M. Hollande, Mme Jourdan, Mme Karamanli, M. Leseul, M. Lhardit, Mme Mercier, M. Naillet, M. Oberti, Mme Pantel, M. Pena, Mme Pic, Mme Pirès Beaune, M. Potier, M. Pribetich, Mme Récalde, Mme Rossi, M. Aurélien Rousseau, M. Roussel, Mme Runel, M. Saint-Pasteur, Mme Santiago, M. Saulignac, M. Simion, M. Sother, Mme Thiébault-Martinez, Mme Thomin, M. Vallaud, M. Vicot et M. William

---

ARTICLE 2 BIS

À l’alinéa 7, substituer à la seconde occurrence du mot :

« président-directeur général »

le mot :

« président des conseils d’administration ».

EXPOSÉ SOMMAIRE

Amendement de repli qui fait évoluer la holding exécutive en holding stratégique. L’amendement prévoit que le président-directeur général de France Médias préside les conseils d’administration des filiales, sans en exercer la direction générale. Chaque filiale est dirigée par un directeur général, nommé par son conseil d’administration sur proposition du président.

En conséquence, il met en cohérence la composition des conseils d’administrations des filiales et de la holding France Médias.

Les directeurs généraux des filiales de France Médias siègent au conseil d’administration de France Médias, afin d’associer pleinement les dirigeants opérationnels à la définition de la stratégie commune. Cette organisation garantit un pilotage plus efficace, une meilleure coordination entre les entités, et une prise en compte réelle des spécificités de chaque média.

Cet amendement a été rédigé suite à des rencontres avec Radio France.

Questions de recherche

- La pratique est-elle répandue ? (RQ1)
- La pratique est-elle uniforme entre les groupes politiques ? (RQ2)
- L'influence déclarée est-elle fructueuse ? (RQ3)

Méthodologiquement : Peut-on identifier les amendements sourcés sur un large corpus en fine-tunant un modèle de type **encoder** à partir d'un **nombre limité d'annotations** ?

Données

Ensemble des amendements de la XVIIème législature de l'Assemblée Nationale (AN) jusqu'au 21-07-2026.

df_original = 123 224 amendements x 25 col
df_clean = 65 388 amendements x 2 col

Retirer les variables inutiles, les amendements dont l'exposé sommaire est vide, les duplicats, les amendements de +1024 tokens.

↳ éviter les annotations contradictoires

↳ fenêtre de contexte maximale recommandée sur l'instance CREST

shape: (65_388, 2)

uid	expose_sommaire
str	str
"AMANR5L17PO838901B1906P2D1N002...	"Cet amendement augmente le bud...
"AMANR5L17PO838901B1906P1D1N001...	"En France, le tabagisme représ...
"AMANR5L17PO838901B1906P1D1N000...	"Cet amendement vise à rehausse...
"AMANR5L17PO838901B2141P0D1N000...	"Afin de répondre aux enjeux cr...
"AMANR5L17PO838901B1906P2D1N000...	"Le présent amendement des dépu...
...	...
"AMANR5L17PO838901BTC1437P0D1N0...	"Le législateur a interdit en 2...
"AMANR5L17PO59048B2247P0D1N0013...	"Sur proposition du collectif C...
"AMANR5L17PO838901B1906P2D1N001...	"Le CNPF est l'établissement pu...
"AMANR5L17PO838901B0325P0D1N001...	"Cet amendement vise à augmente...
"AMANR5L17PO849474B0481P0D1N001...	"La procédure de sanction simpl...

identifiant unique

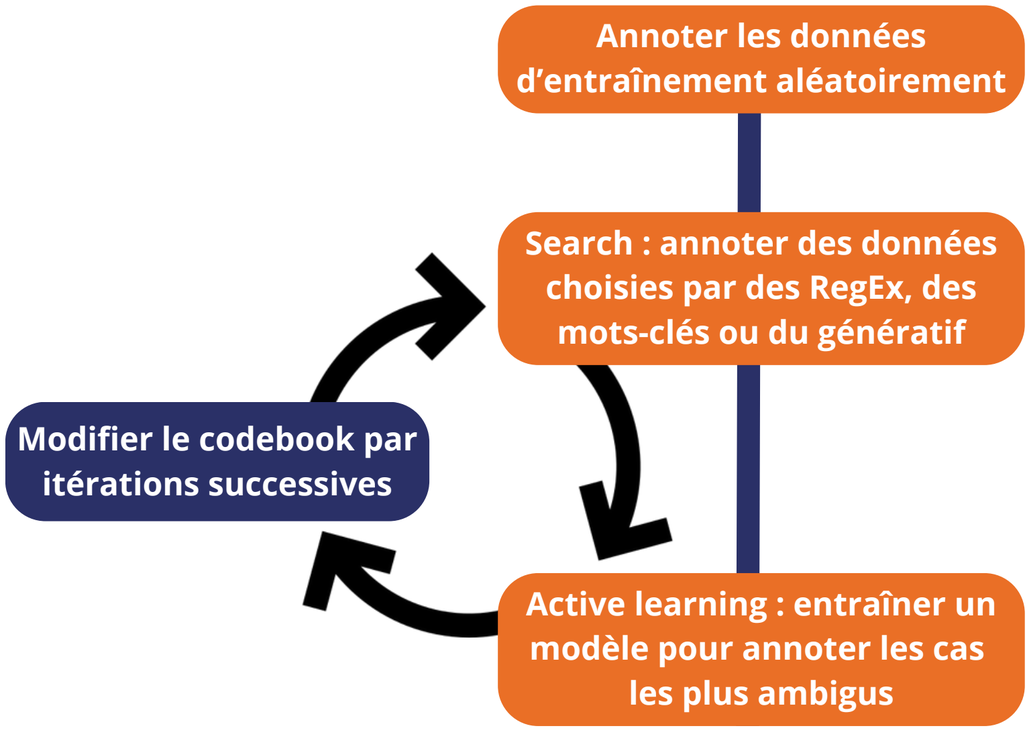
texte



Rappel : le workflow d’un projet ActiveTigger

Étape 1 : Création du projet

Étape 2 : Annoter les données d’entraînement et fixer son codebook



Étape 3 : Annoter les données de validation et de test

Étape 4 : Entraîner des modèles



Train Set

Étape 5 : Sélectionner un modèle



Validation Set

Étape 6 : Évaluer le modèle



Test Set

Étape 7 : Étendre la prédiction à tout le corpus



Données restantes

Annoter les données d’entraînement et fixer son codebook (étape 2)

Annoter

1) Aléatoirement

2) par RegEx

3) par Active learning



Annoter les données d’entraînement et fixer son codebook (étape 2)

Fixer son codebook

Par itérations successives

Guidelines

On définit deux étiquettes : **source** et **non-source**.

- Un amendement est **source** quand il a été suggéré par ou travaillé avec un représentant d’intérêt et que son origine est exprimée explicitement comme telle. On entend par "représentant d’intérêt" un groupe ou une institution extérieure à la représentation politique, représentant des intérêts privés.

Cette définition reprend celle de la Haute Autorité pour la Transparence de la Vie Publique (HATVP) (à consulter ici) mais élargit son champ en n'exigeant pas une personnalité morale du représentant d'intérêt. Les collectifs ou une profession, par exemple, sont donc inclus.

- Un amendement est **non-source** dans tous les autres cas.

Exemples :

- “(...) Cet amendement a été travaillé avec la FNSEA.” est **source**.

  Il est explicitement mentionné que l’amendement est issu d’une collaboration avec un syndicat professionnel.

- “(...) Cet amendement est un amendement de repli proposé par L214. (...) ” est **source**.

  Il est explicitement mentionné que l’amendement a été suggéré par une association.

- “(...) Ainsi, selon l’Unef, les prix des produits alimentaires ont augmenté de 1,4 % cette année. (...)” est **non-source**.

  L’amendement n’établit pas de lien explicite entre le dépôt de l’amendement et cette organisation. Il cite simplement une donnée extérieure.

- “(...) Le présent amendement avait été adopté par la Commission du développement durable et de l'aménagement du territoire.” est **non-source**.

  Cette Commission est une commission permanente de l’Assemblée Nationale. Ce n’est pas une institution extérieure à la représentation politique.

- “(...) Cet amendement a été travaillé avec Départements de France.” est **non-source**.

  Départements de France est une association d'élus locaux. Elle fédère des hommes et femmes exerçant un mandat de représentation politique dans le cadre de leur fonction. D'après notre définition et celle de la HATVP, cette association ne peut pas être qualifiée de représentant d'intérêt. Une liste de ces associations peut être trouvée ici.

Entraîner des modèles (étape 4)

Choisir un ou des modèles dont les caractéristiques correspondent à nos données.

cf. documentation sur Hugging Face

On utilise ici **CamembertaV2base**

- Francophone
- Fenêtre de contexte de +1024 tokens
- Données d’entraînement conviennent

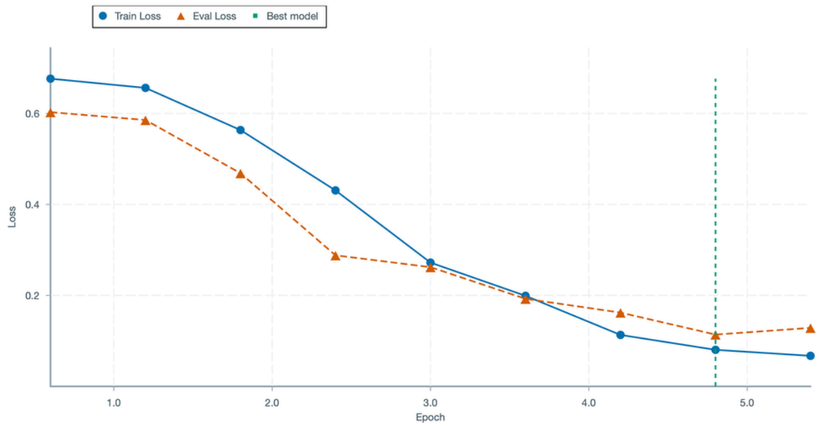
Sélectionner un modèle (étape 5)

Sélection du modèle le plus performant sur le set de validation.

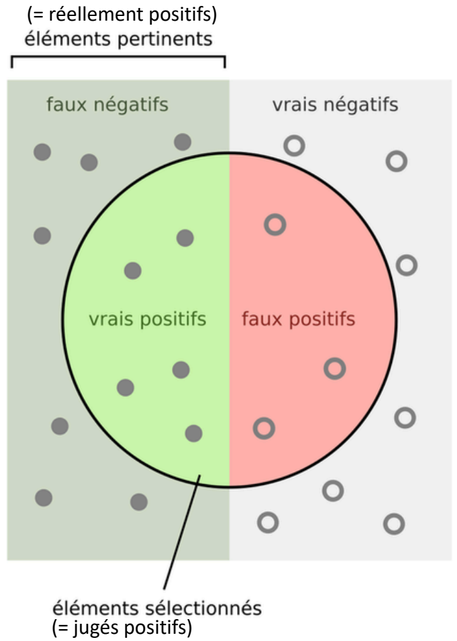
Modèle B Macro F1 score on valid set : **1**

	Recall	Precision	F1
source	1	1	1
non-source	1	1	1

Note : losses d'entraînement



Focus modèles : Que signifient les scores ?



Combien d'éléments sélectionnés sont pertinents ?

$$\text{Précision} = \frac{\text{vrais positifs}}{\text{éléments sélectionnés}}$$

proche de 1 = le modèle ne sélectionne presque que des éléments pertinents.

Combien d'éléments pertinents sont sélectionnés ?

$$\text{Rappel} = \frac{\text{vrais positifs}}{\text{éléments pertinents}}$$

proche de 1 = le modèle sélectionne presque tous les éléments pertinents.

	Recall	Precision	F1
source	0.943	0.846	0.892
non-source	0.929	0.975	0.952

moyenne harmonique de recall et precision

moyenne des F1 de chaque label

Macro F1 score on Train-Eval set : **0.922**

Évaluer le modèle (étape 6)

Évaluation du modèle sélectionné sur le set de test.

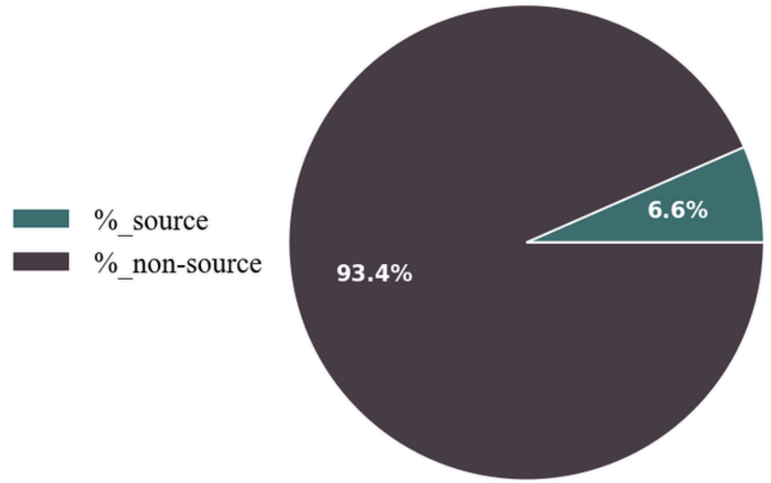
Modèle B Macro F1 score on test set : **0.964**

	Recall	Precision	F1
source	1	0.875	0.933
non-source	0.989	1	0.995

Résultats

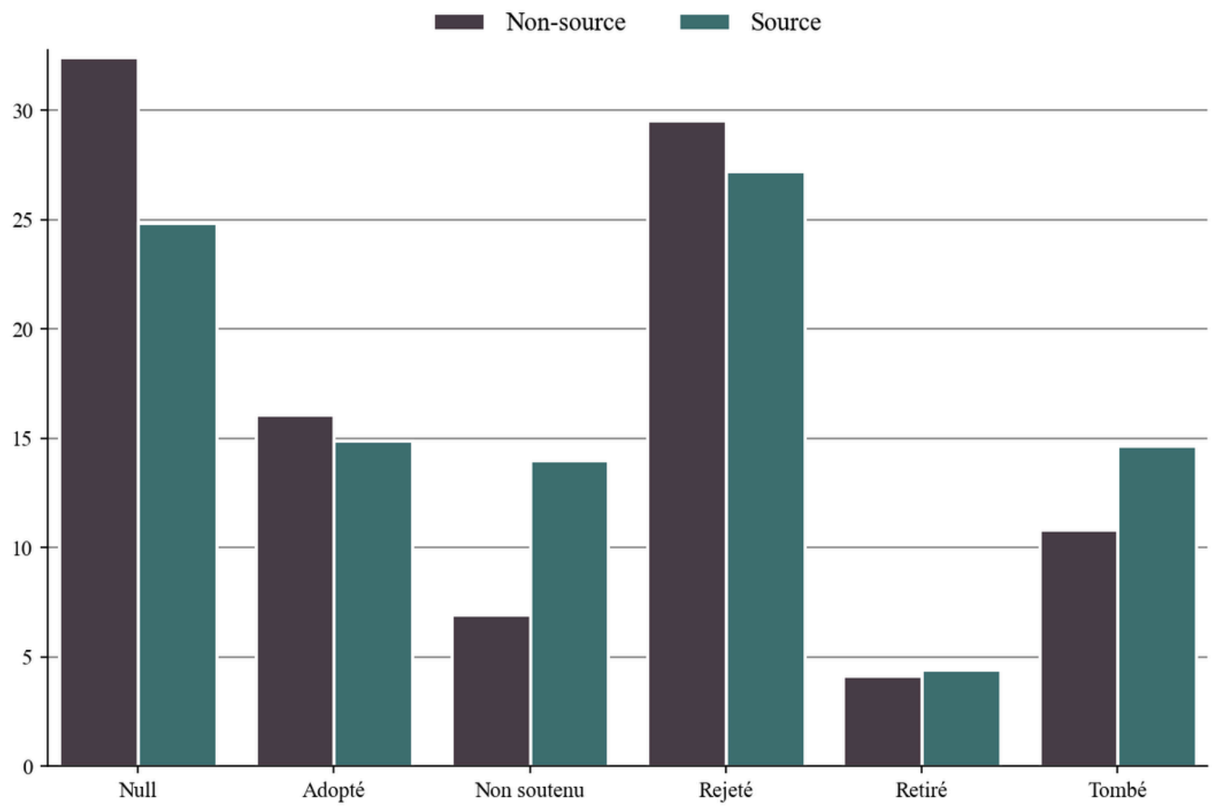
(RQ1) : Pratique minoritaire mais non marginale.

Répartition des amendements de la XVIIème législature* selon leur sourcing (en %)



*à l'exclusion des amendements dont l'exposé sommaire est null ou d'une longueur >1024 tokens.

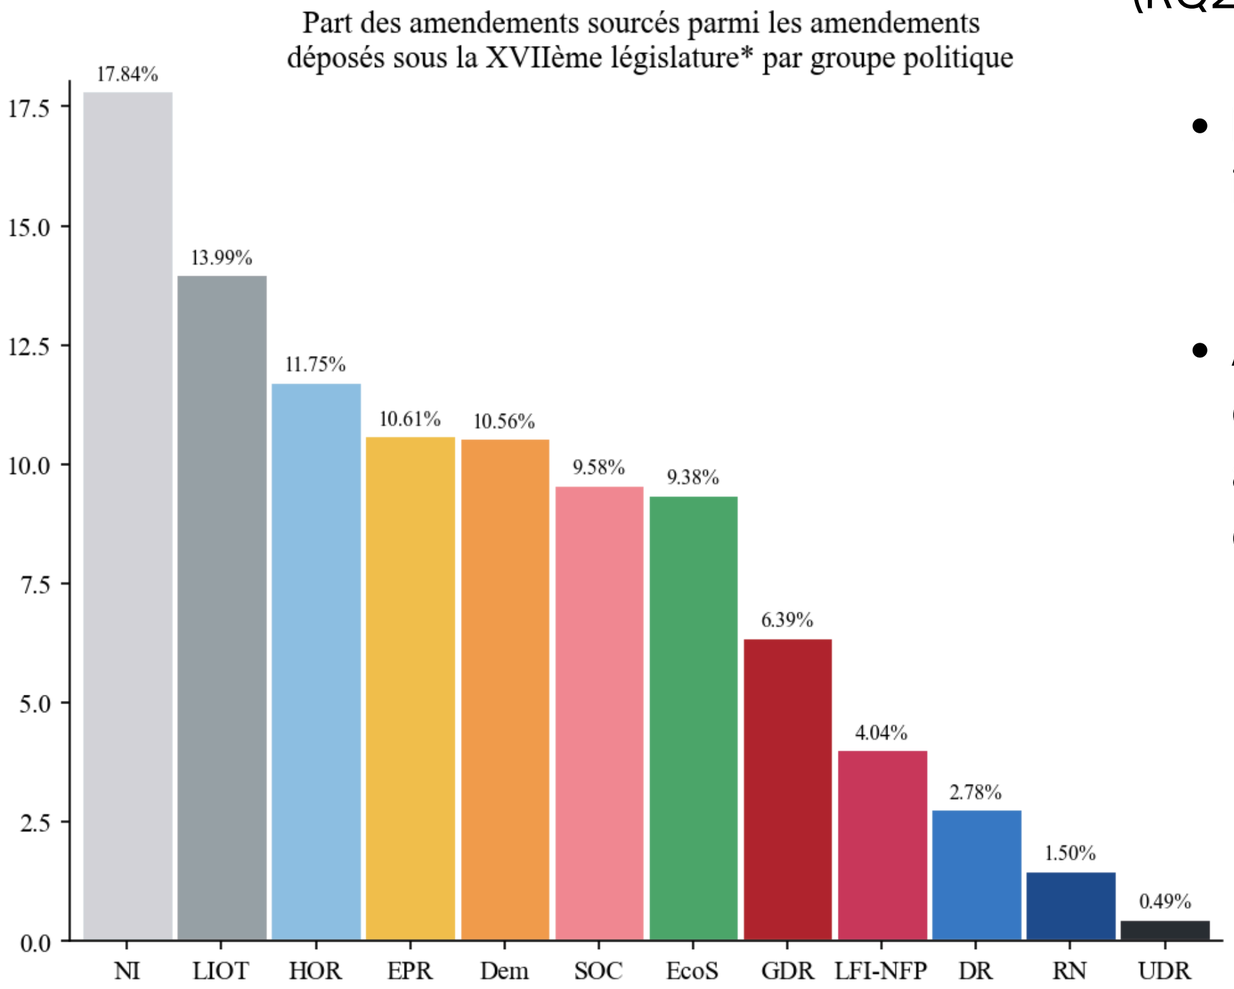
Sort des amendements de la XVIIème législature* selon leur nature (en %)



*à l'exclusion des amendements dont l'exposé sommaire est null ou d'une longueur >1024 tokens.

(RQ3) : Les amendements "source" ne sont pas davantage adoptés que les "non-source".

Résultats

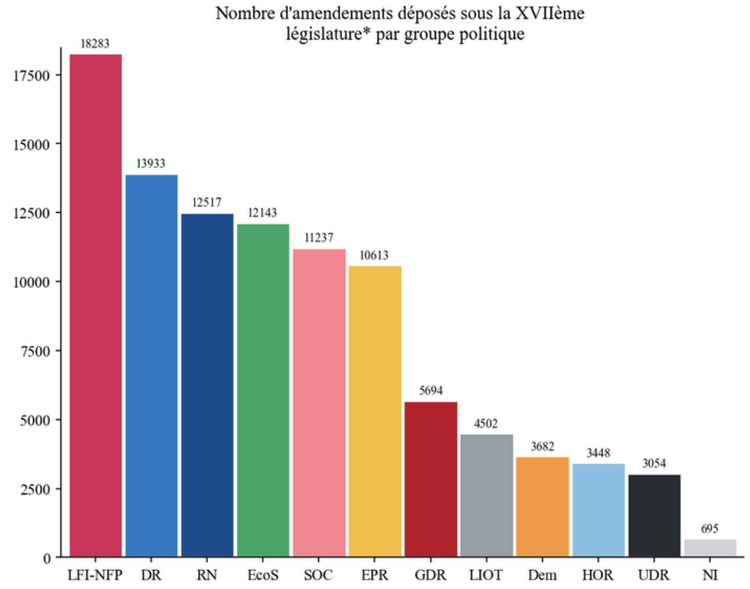


*à l'exclusion des amendements dont l'exposé sommaire est null ou d'une longueur >1024 tokens.

(RQ2) : Différence substantielle entre groupes politiques.

- Les NI et LIOT sont-ils plus soumis à influence ou plus transparents ?

- À mettre au regard du volume des amendements déposés



Intérêt, limites

Est-ce qu'un decoder (Claude, ChatGPT) aurait pu le faire ?

Si le codebook est déjà optimal, oui.

MAIS mettre en perspective la nature de notre cas :

- Codebook amélioré : **Augmentation** de la chercheuse ou du chercheur
- **Simplicité de la tâche** (peu d'appréciation subjective)
- **Absence de sensibilité des données**
- **Coût temporel limité** (peu d'annotations)

À cela s'ajoutent :

- **Coûts économique, environnemental**
- **Réplicabilité**



Merci !

Demande de compte, documentation, lien GitHub, lien Discord :
https://activetigger.com