

Use Case : les amendements de la XVIIème législature de l’Assemblée Nationale

Objectif : classer automatiquement ces amendements comme **sourcés** ou **non-sourcés** avec ActiveTigger.

Plan de la session

Introduction : contexte, questions de recherche et données

1. Créer un projet
2. Annoter les données d’entraînement et fixer son codebook
3. Annoter les données de validation et de test
4. Entraîner des modèles
5. Sélectionner un modèle
6. Évaluer le modèle
7. Étendre les prédictions



ActiveTigger

8. Résultats
9. Intérêt et limites de notre cas

Contexte

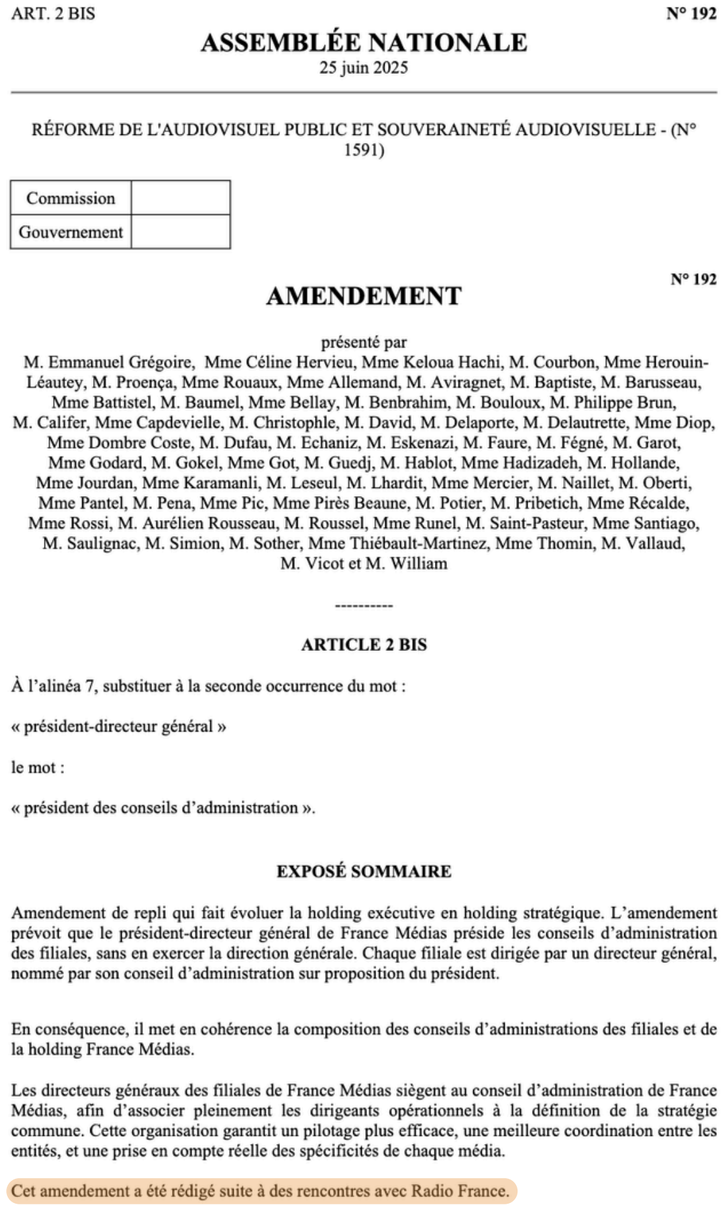
Un amendement résulte de nombreuses interactions.

Certains sont discutés avec ou proposés par un ou plusieurs groupe(s) d'intérêt ("lobbies")

Sourcing des amendements : citer nommément ces groupes et la nature de leur influence sur la soumission d'un amendement donné dans l'exposé des motifs.

➔ "Bonne pratique" promue par un certain nombre de parlementaires mais non obligatoire

(cf. tribune de 322 élus et élues LREM dans Le Monde en octobre 2019)



ART. 2 BIS N° 192

ASSEMBLÉE NATIONALE

25 juin 2025

RÉFORME DE L'AUDIOVISUEL PUBLIC ET SOUVERAINETÉ AUDIOVISUELLE - (N° 1591)

Commission	
Gouvernement	

N° 192

AMENDEMENT

présenté par

M. Emmanuel Grégoire, Mme Céline Hervieu, Mme Keloua Hachi, M. Courbon, Mme Herouin-Léautey, M. Proença, Mme Rouaux, Mme Allemand, M. Aviragnet, M. Baptiste, M. Barusseau, Mme Battistel, M. Baumel, Mme Bellay, M. Benbrahim, M. Bouloux, M. Philippe Brun, M. Califer, Mme Capdevielle, M. Christophle, M. David, M. Delaporte, M. Delautrette, Mme Diop, Mme Dombre Coste, M. Dufau, M. Echaniz, M. Eskenazi, M. Faure, M. Fégné, M. Garot, Mme Godard, M. Gokel, Mme Got, M. Guedj, M. Hablot, Mme Hadizadeh, M. Hollande, Mme Jourdan, Mme Karamanli, M. Leseul, M. Lhardit, Mme Mercier, M. Naillet, M. Oberti, Mme Pantel, M. Pena, Mme Pic, Mme Pirès Beaune, M. Potier, M. Pribetich, Mme Récalde, Mme Rossi, M. Aurélien Rousseau, M. Roussel, Mme Runel, M. Saint-Pasteur, Mme Santiago, M. Saulignac, M. Simion, M. Sother, Mme Thiébault-Martinez, Mme Thomin, M. Vallaud, M. Vicot et M. William

---

ARTICLE 2 BIS

À l'alinéa 7, substituer à la seconde occurrence du mot :

« président-directeur général »

le mot :

« président des conseils d'administration ».

EXPOSÉ SOMMAIRE

Amendement de repli qui fait évoluer la holding exécutive en holding stratégique. L'amendement prévoit que le président-directeur général de France Médias préside les conseils d'administration des filiales, sans en exercer la direction générale. Chaque filiale est dirigée par un directeur général, nommé par son conseil d'administration sur proposition du président.

En conséquence, il met en cohérence la composition des conseils d'administrations des filiales et de la holding France Médias.

Les directeurs généraux des filiales de France Médias siègent au conseil d'administration de France Médias, afin d'associer pleinement les dirigeants opérationnels à la définition de la stratégie commune. Cette organisation garantit un pilotage plus efficace, une meilleure coordination entre les entités, et une prise en compte réelle des spécificités de chaque média.

Cet amendement a été rédigé suite à des rencontres avec Radio France.

sourcing !

Questions de recherche

- La pratique est-elle répandue ? (RQ1)
- La pratique est-elle uniforme entre les groupes politiques ? (RQ2)
- L'influence déclarée est-elle fructueuse ? (RQ3)

Méthodologiquement : Peut-on identifier les amendements sourcés sur un large corpus en fine-tunant un modèle de type **encoder** à partir d'un **nombre limité d'annotations** ?

Données

Ensemble des amendements de la XVIIème législature de l'Assemblée Nationale (AN) jusqu'au 21-07-2026.

n_original = 123 224 amendements
n_clean = 65 388 amendements

Retirer les variables inutiles, les amendements dont l'exposé sommaire est vide, les duplicats, les amendements de +1024 tokens.

↳ éviter les annotations contradictoires

↳ fenêtre de contexte maximale recommandée sur l'instance CREST

shape: (65_388, 2)

uid	expose_sommaire
str	str
"AMANR5L17PO838901B1906P2D1N002...	"Cet amendement augmente le bud...
"AMANR5L17PO838901B1906P1D1N001...	"En France, le tabagisme représ...
"AMANR5L17PO838901B1906P1D1N000...	"Cet amendement vise à rehausse...
"AMANR5L17PO838901B2141P0D1N000...	"Afin de répondre aux enjeux cr...
"AMANR5L17PO838901B1906P2D1N000...	"Le présent amendement des dépu...
...	...
"AMANR5L17PO838901BTC1437P0D1N0...	"Le législateur a interdit en 2...
"AMANR5L17PO59048B2247P0D1N0013...	"Sur proposition du collectif C...
"AMANR5L17PO838901B1906P2D1N001...	"Le CNPF est l'établissement pu...
"AMANR5L17PO838901B0325P0D1N001...	"Cet amendement vise à augmente...
"AMANR5L17PO849474B0481P0D1N001...	"La procédure de sanction simpl...

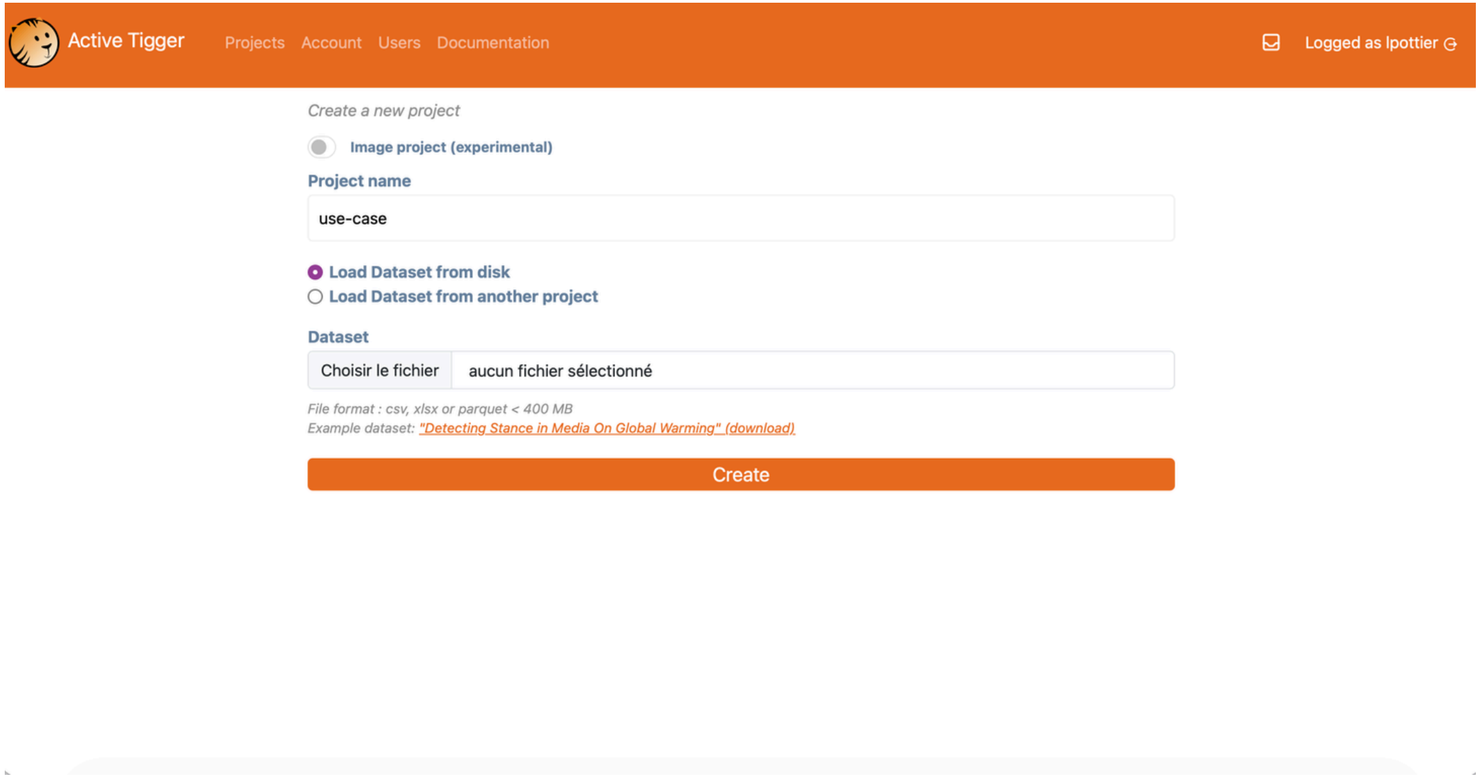
identifiant unique

texte

Étape 1 : créer un projet

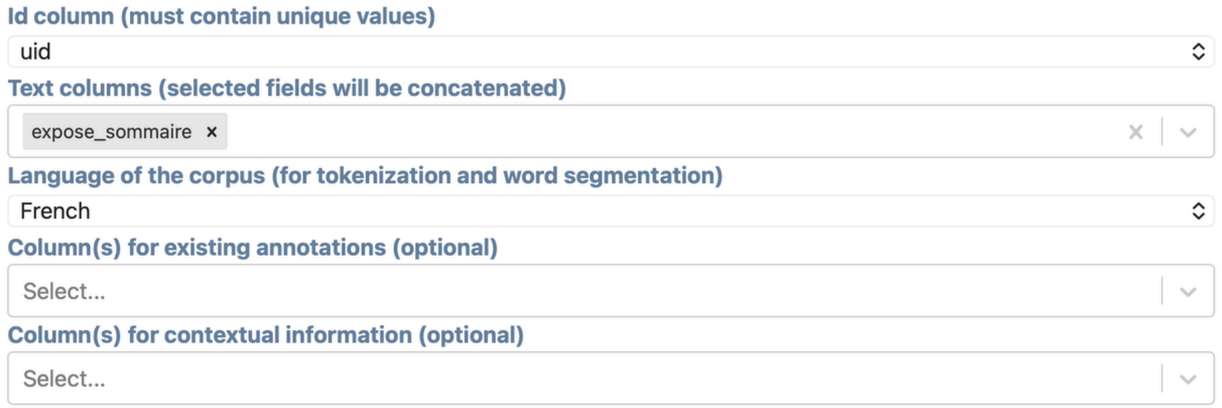
1. Cliquer sur 

2. Choisir le nom du projet et sélectionner le dataset depuis votre disque



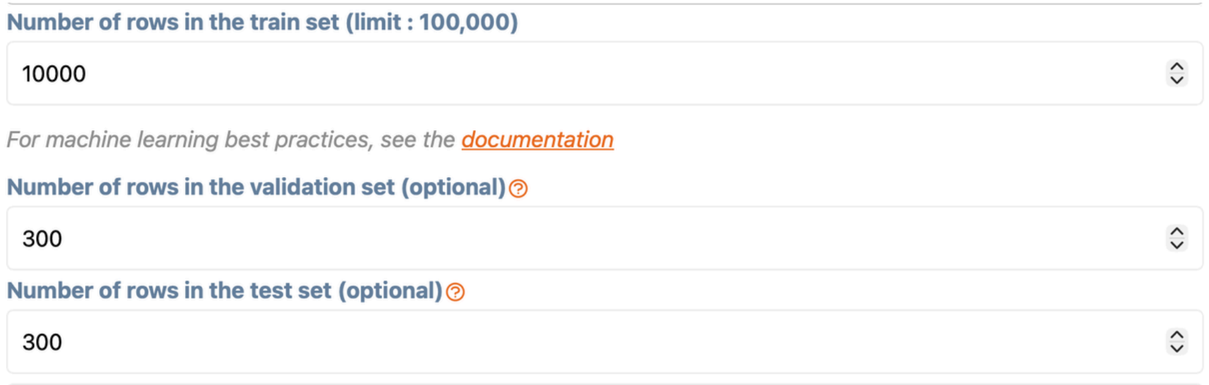
Étape 1 : créer un projet

3. Remplir les informations demandées sur notre dataset



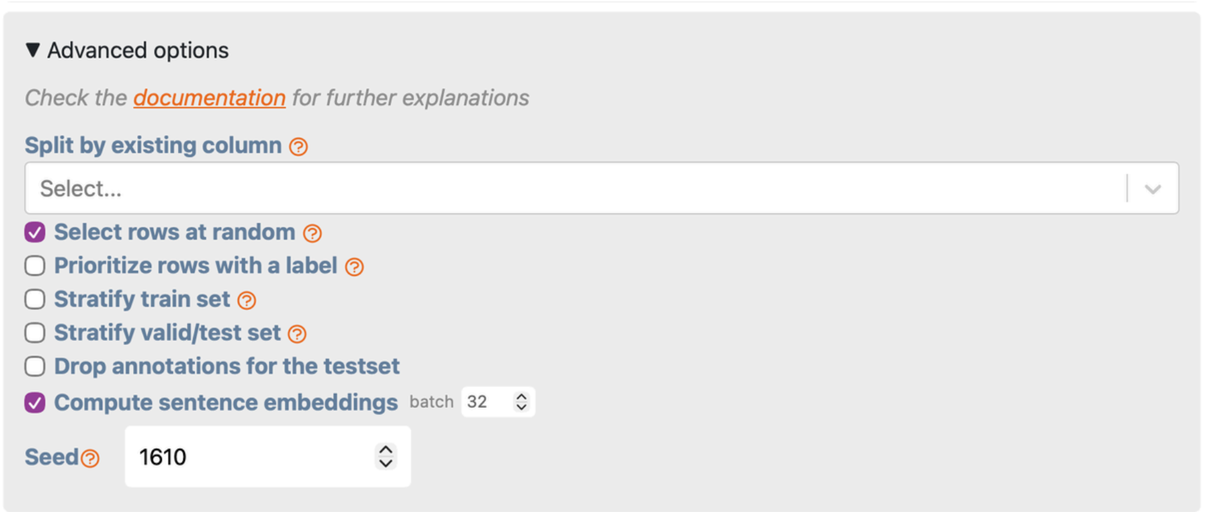
4. Sélectionner la taille des **train**, **validation** et **test sets**.

- Train : défaut 10 000 (tout ne sera pas annoté)
- Valid, Test : commençons par 300. Le label “source” a une prévalence de 8-9%, on aura ≈26 items par set.



Étape 1 : créer un projet

(5-Optionnel.) Possibilité de sélectionner des options avancées, cf. documentation.



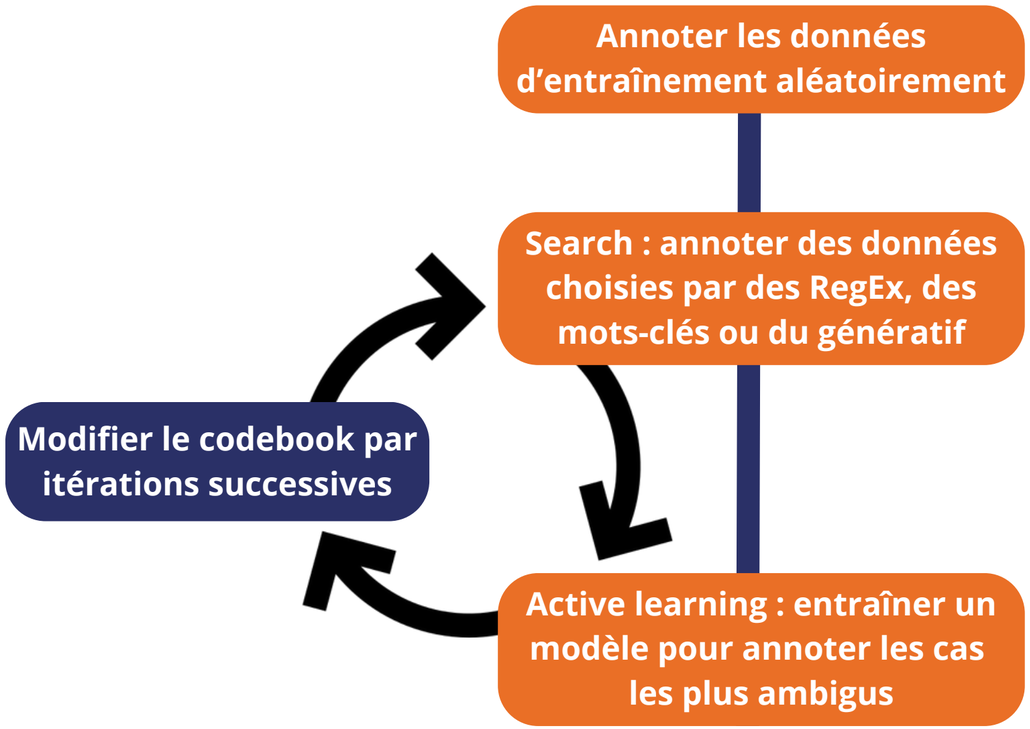
6. Cliquer sur 

Votre projet est créé !

Rappel : le workflow d’un projet ActiveTigger

Étape 1 : Création du projet

Étape 2 : Annoter les données d’entraînement et fixer son codebook



Étape 3 : Annoter les données de validation et de test

Étape 4 : Entraîner des modèles



Train Set

Étape 5 : Sélectionner un modèle



Validation Set

Étape 6 : Évaluer le modèle



Test Set

Étape 7 : Étendre la prédiction à tout le corpus



Données restantes

Étape 2 : annoter les données d’entraînement et fixer son codebook

Pour pouvoir annoter, il nous faut créer un premier codebook.

Deux catégories (aussi appelées labels, étiquettes) :

- source
- non-source

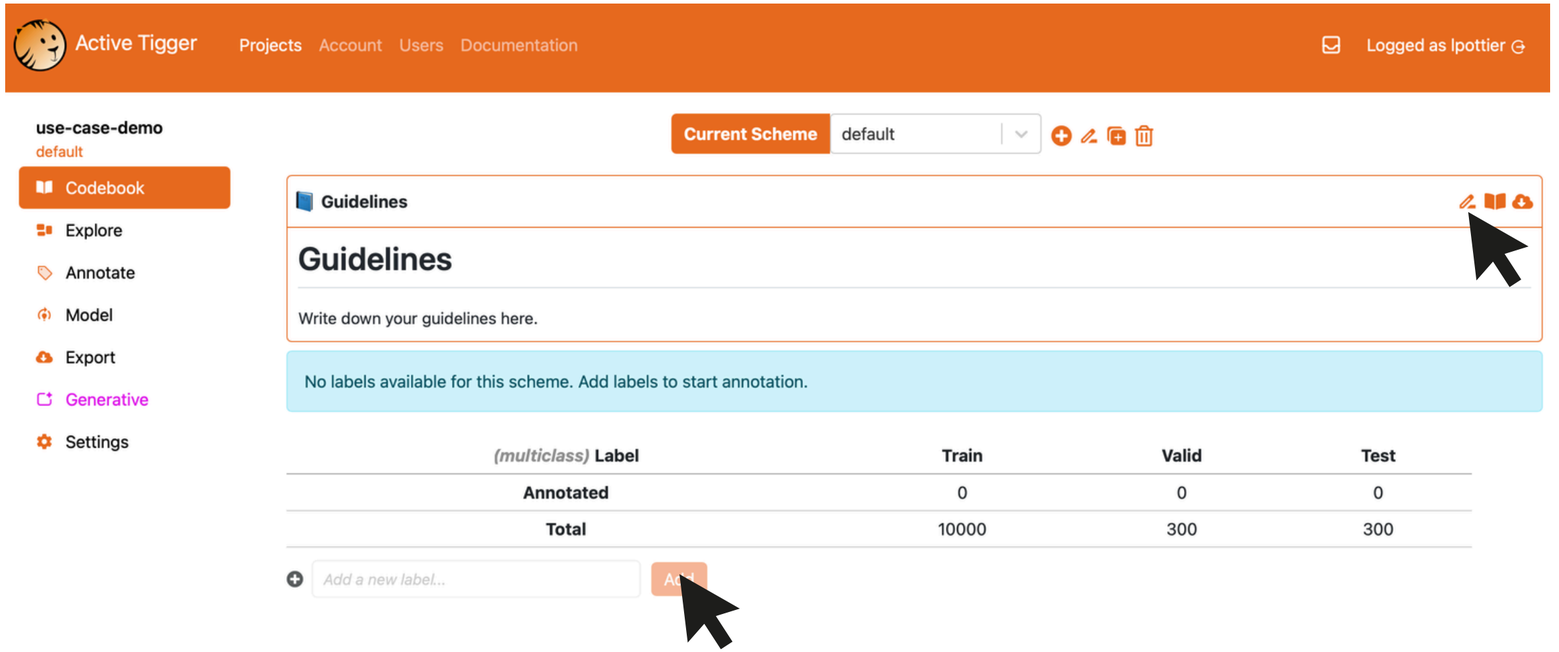
Partons d’une définition simple (et un peu naïve) :

1. Un amendement est **source** quand il a été travaillé avec un représentant d’intérêt et que son origine est exprimée explicitement comme telle.

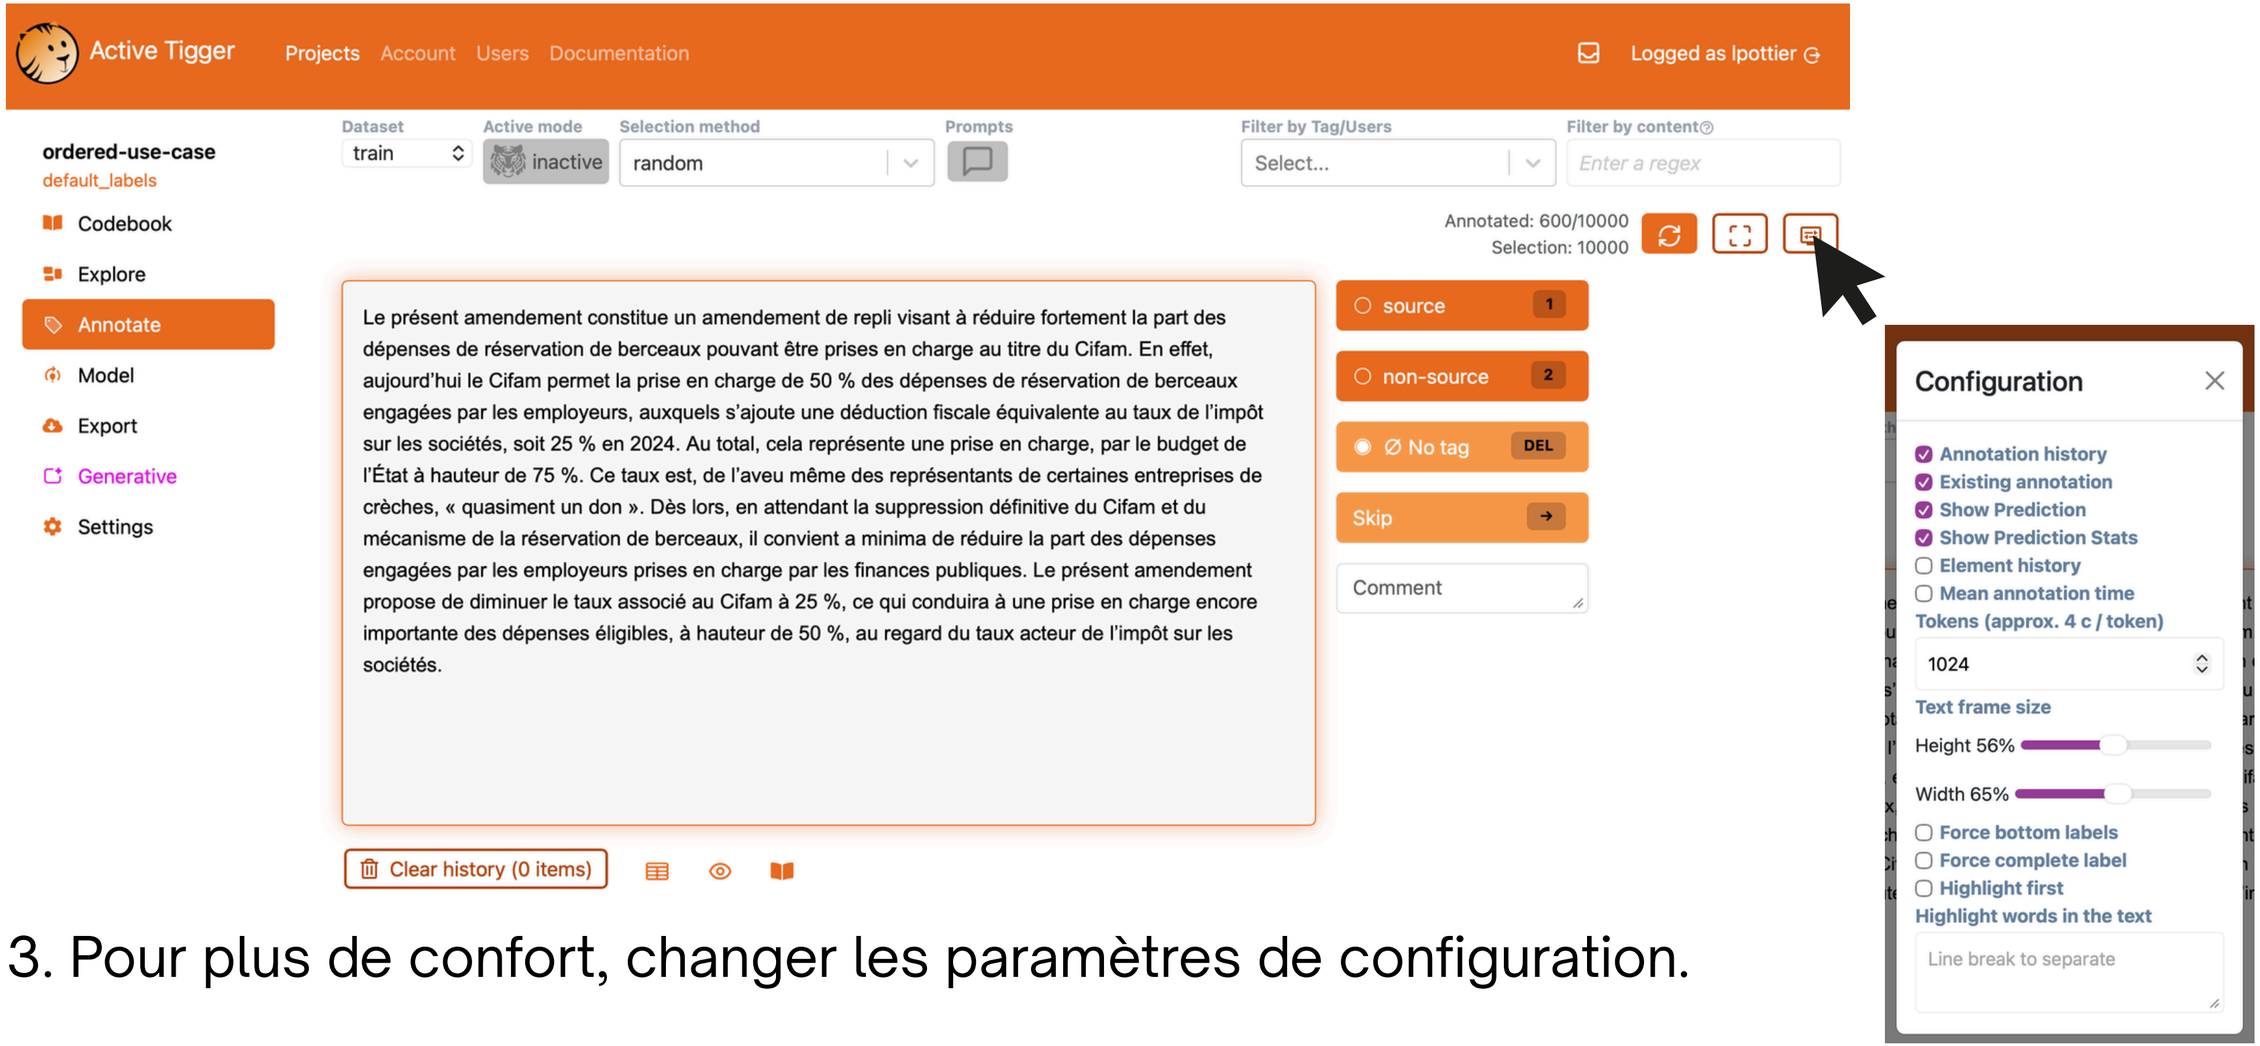
   Un amendement est **non-source** dans tous les autres cas.

Étape 2 : annoter les données d’entraînement et fixer son codebook

1. Créons les deux labels (source et non-source) : les taper puis cliquer sur Add.
2. Rentrons notre premier codebook : cliquer sur l’icône stylo et ajouter le texte.



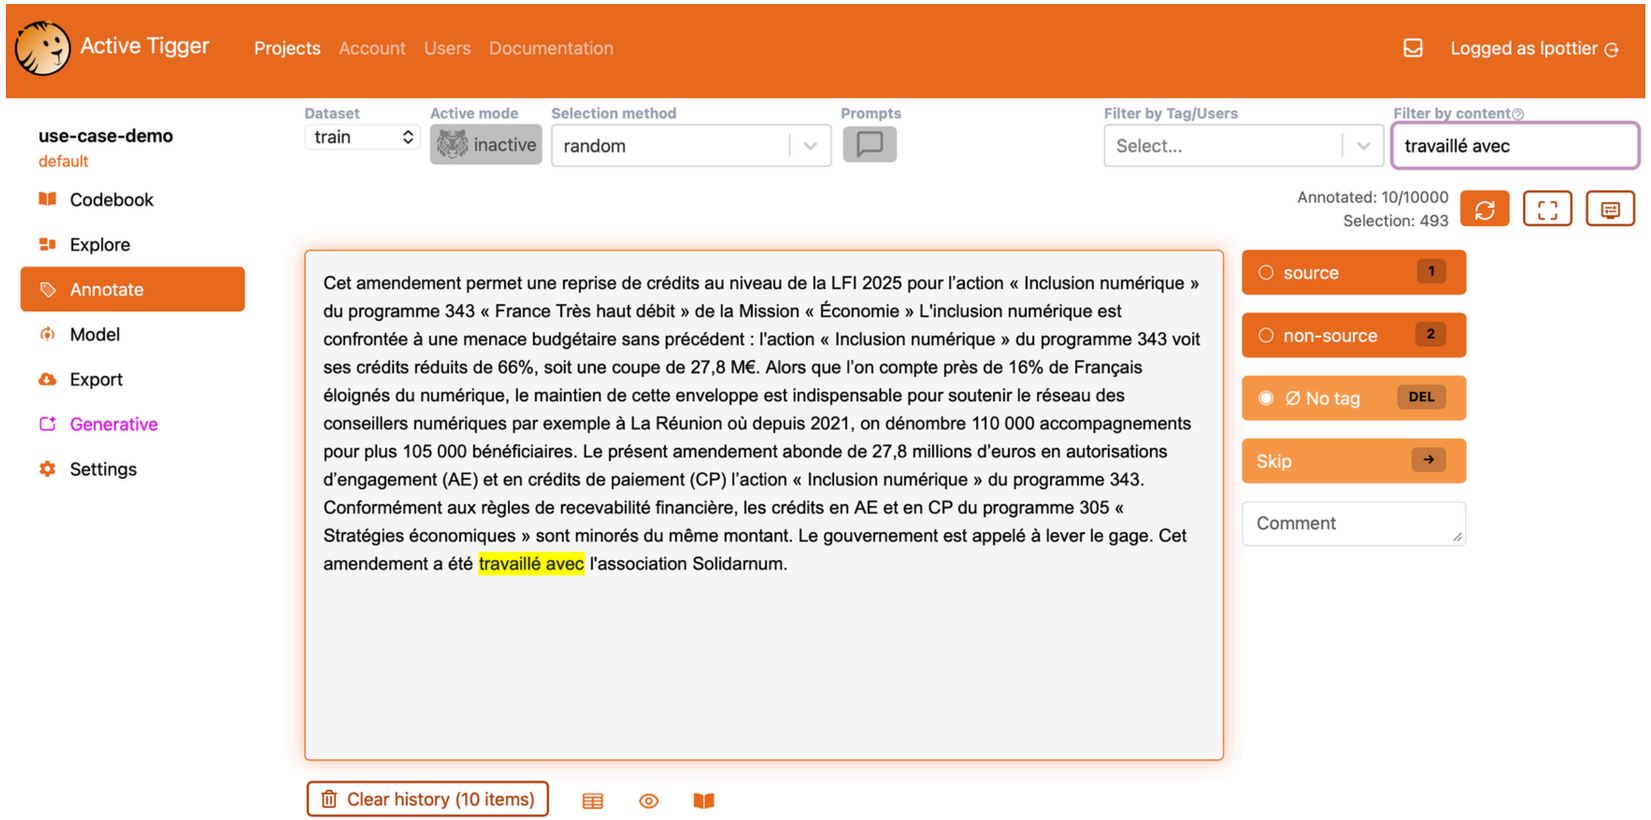
Étape 2 : annoter les données d’entraînement et fixer son codebook



3. Pour plus de confort, changer les paramètres de configuration.

Étape 2 : annoter les données d’entraînement et fixer son codebook

4. C’est parti : annotons une dizaine d’amendements de façon aléatoire.
On apprend à connaître nos données.

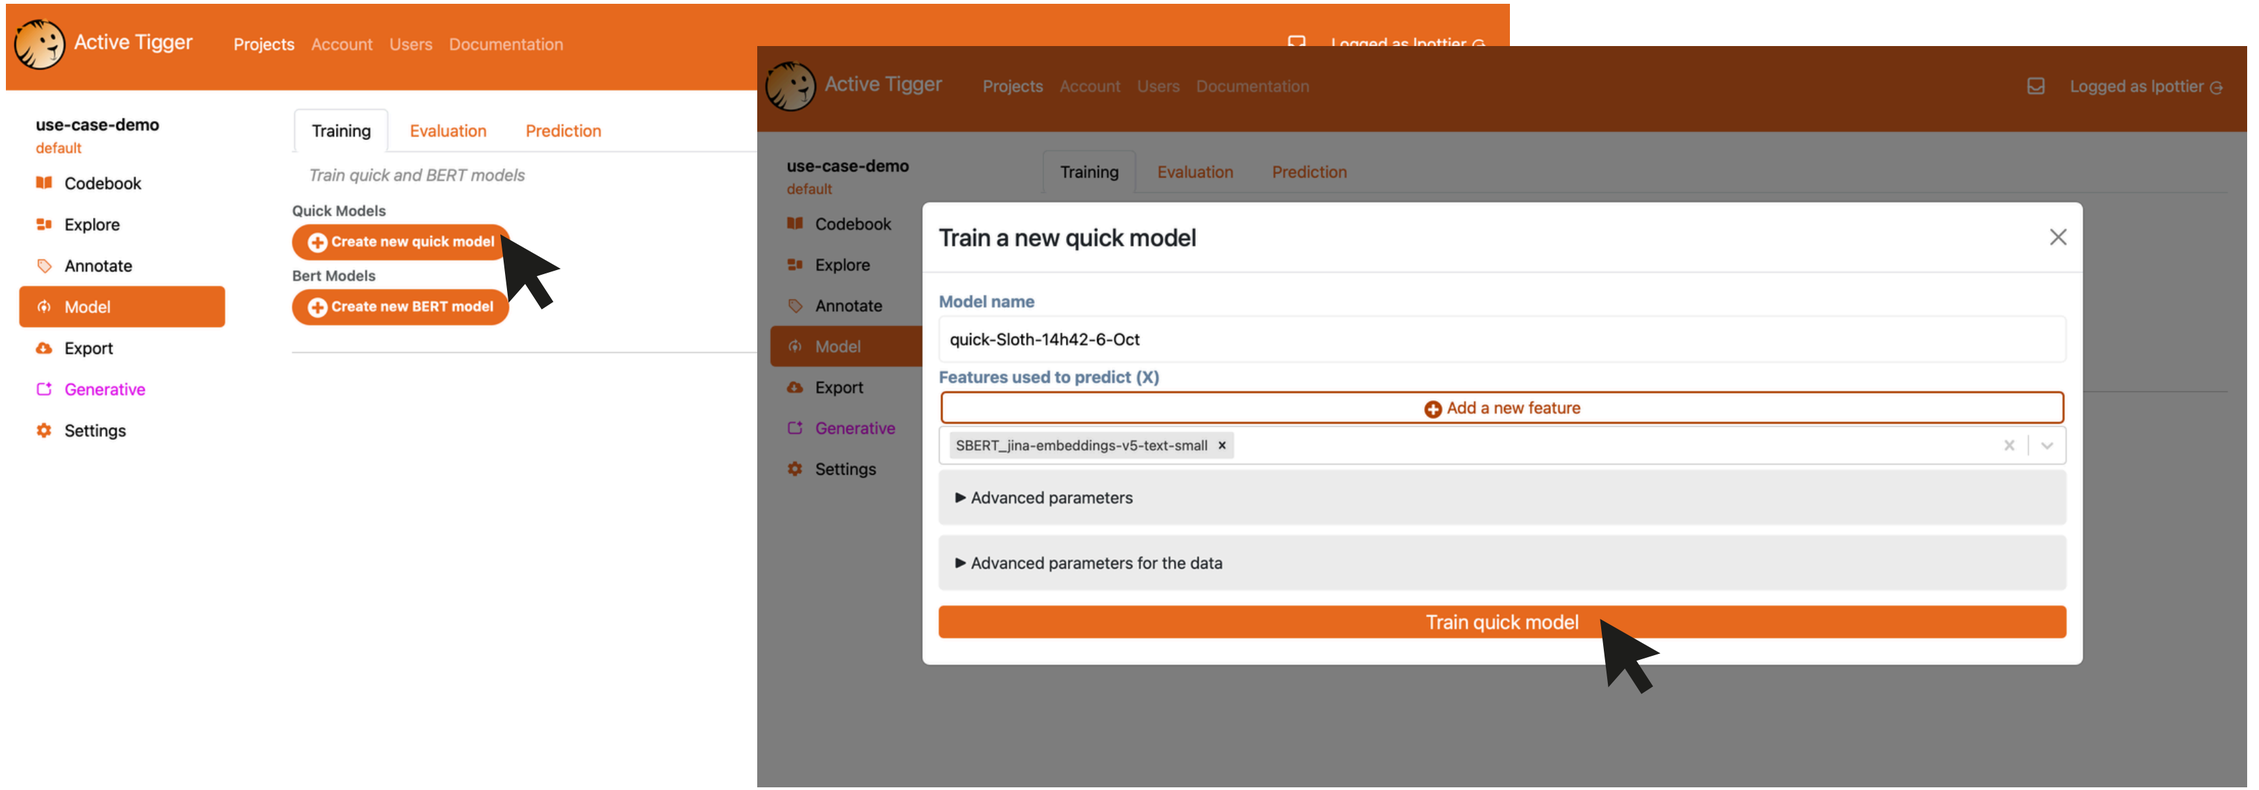


5. Le *sourcing* se matérialise souvent par la présence de la phrase suivante : “Cet amendement a été travaillé avec xx”.

Annotons les amendements qui contiennent “travaillé avec”.

Étape 2 : annoter les données d’entraînement et fixer son codebook

6. On a maintenant assez de données pour entraîner un premier modèle, qui va nous permettre d’annoter en utilisant l’**active learning**.



Étape 2 : annoter les données d’entraînement et fixer son codebook

7. Annotons quelques d’amendements en utilisant l’active learning.



Nous pourrons ensuite entraîner d’autres modèles pour améliorer les prédictions et donc la sélection des cas difficiles.

Étape 2 : annoter les données d’entraînement et fixer son codebook

Au fil des annotations, on rencontre des cas difficiles qui font évoluer notre codebook.

DÉPART

1 Un amendement est **source** quand il a été travaillé avec un représentant d’intérêt et que son origine est exprimée explicitement comme telle.

Un amendement est **non-source** dans tous les autres cas.

(…) **Cet amendement a été suggéré par la Fondation pour la Nature et l’Homme.**

PB : suggérer ≠ travailler avec

2 *Modif*: Un amendement est source quand il a été **suggéré par ou** travaillé avec un représentant d’intérêt et que son origine est exprimée explicitement comme telle.

Étape 2 : annoter les données d’entraînement et fixer son codebook

Au fil des annotations, on rencontre des cas difficiles qui font évoluer notre codebook.

Cet amendement **adopté en commission du développement durable** propose (...)

PB : source explicite mais pas un représentant d’intérêt.
=> Redéfinir la RQ vers l’identification de l’origine des amendements, quelle qu’elle soit ? Choix : non.

Le présent amendement, **soutenu par l’Association des maires de France (AMF)**, vise à supprimer (...)

PB : associations d’élus et élues sont-elles des “lobbies” ? Choix : non (appui sur HATVP).

3 *Ajout:* On entend par "représentant d’intérêt" un groupe ou une institution extérieure à la représentation politique, représentant des intérêts privés, conformément à la définition de la HATVP.

Étape 2 : annoter les données d’entraînement et fixer son codebook

Au fil des annotations, on rencontre des cas difficiles qui font évoluer notre codebook.

(...) Cet amendement a été élaboré en concertation **avec la profession.**

(...) Cet amendement a été travaillé **avec le collectif** oui au train de nuit.

PB : “profession” et “collectif” ne rentrent pas dans la définition de la HATVP.

=> Les inclure ? Choix : oui.

4

Modif: On entend par "représentant d’intérêt" un groupe ou une institution extérieure à la représentation politique, représentant des intérêts privés.

Ajout: Cette définition reprend celle de la HATVP mais élargit son champ en n'exigeant pas une personnalité morale du représentant d'intérêt.

Étape 2 : annoter les données d’entraînement et fixer son codebook

Codebook final

Guidelines

On définit deux étiquettes : **source** et **non-source**.

- Un amendement est **source** quand il a été suggéré par ou travaillé avec un représentant d’intérêt et que son origine est exprimée explicitement comme telle. On entend par "représentant d’intérêt" un groupe ou une institution extérieure à la représentation politique, représentant des intérêts privés.

Cette définition reprend celle de la Haute Autorité pour la Transparence de la Vie Publique (HATVP) (à consulter ici) mais élargit son champ en n'exigeant pas une personnalité morale du représentant d'intérêt. Les collectifs ou une profession, par exemple, sont donc inclus.

- Un amendement est **non-source** dans tous les autres cas.

Exemples :

- “(...) Cet amendement a été travaillé avec la FNSEA.” est **source**.

  Il est explicitement mentionné que l’amendement est issu d’une collaboration avec un syndicat professionnel.

- “(...) Cet amendement est un amendement de repli proposé par L214. (...) ” est **source**.

  Il est explicitement mentionné que l’amendement a été suggéré par une association.

- “(...) Ainsi, selon l’Unef, les prix des produits alimentaires ont augmenté de 1,4 % cette année. (...)” est **non-source**.

  L’amendement n’établit pas de lien explicite entre le dépôt de l’amendement et cette organisation. Il cite simplement une donnée extérieure.

- “(...) Le présent amendement avait été adopté par la Commission du développement durable et de l'aménagement du territoire.” est **non-source**.

  Cette Commission est une commission permanente de l’Assemblée Nationale. Ce n’est pas une institution extérieure à la représentation politique.

- “(...) Cet amendement a été travaillé avec Départements de France.” est **non-source**.

  Départements de France est une association d'élus locaux. Elle fédère des hommes et femmes exerçant un mandat de représentation politique dans le cadre de leur fonction. D'après notre définition et celle de la HATVP, cette association ne peut pas être qualifiée de représentant d'intérêt. Une liste de ces associations peut être trouvée ici.

Étape 3 : annoter les validation et test sets

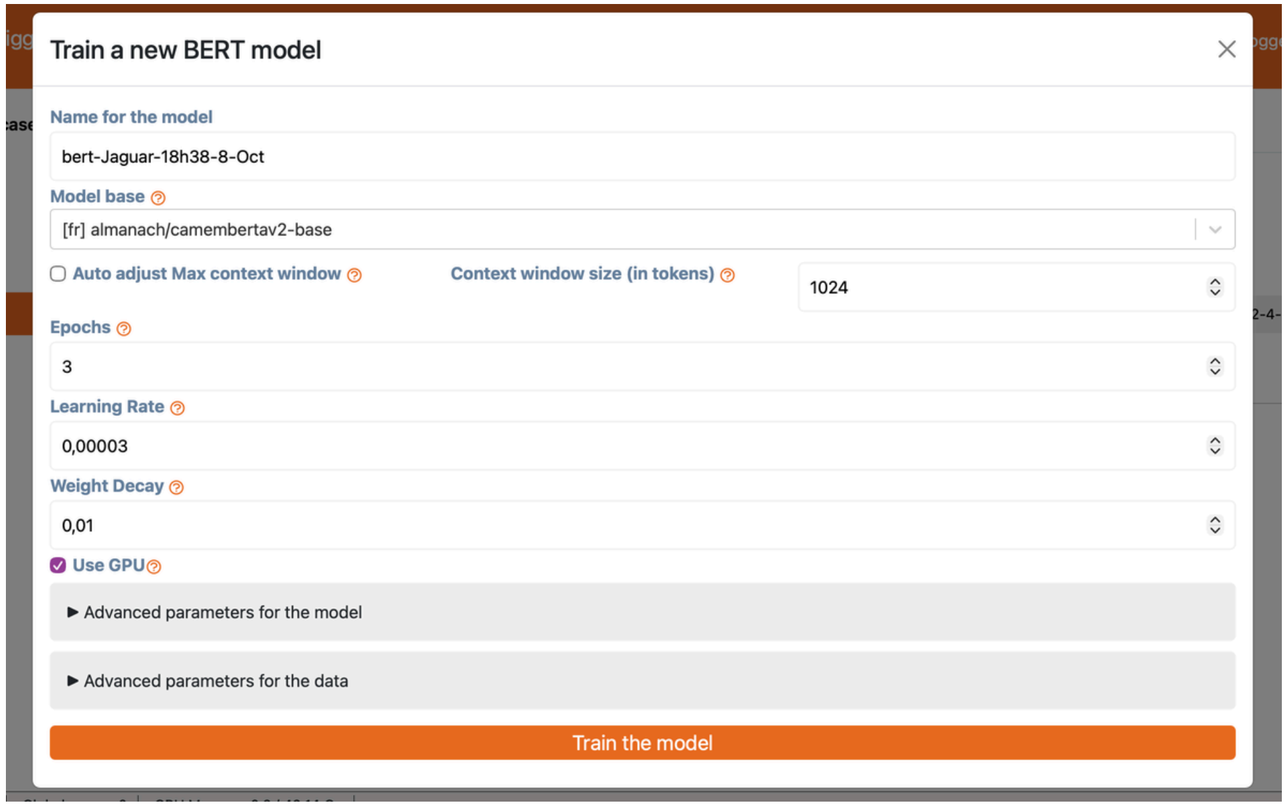
Maintenant que notre codebook est fixé, on peut annoter les données de validation et de test.



Étape 4 : entraîner des modèles

Choisir un ou des modèles dont les caractéristiques correspondent à nos données.

cf. documentation sur Hugging Face



On essaie **CamembertaV2base** et **ModernCamemBERTbase**

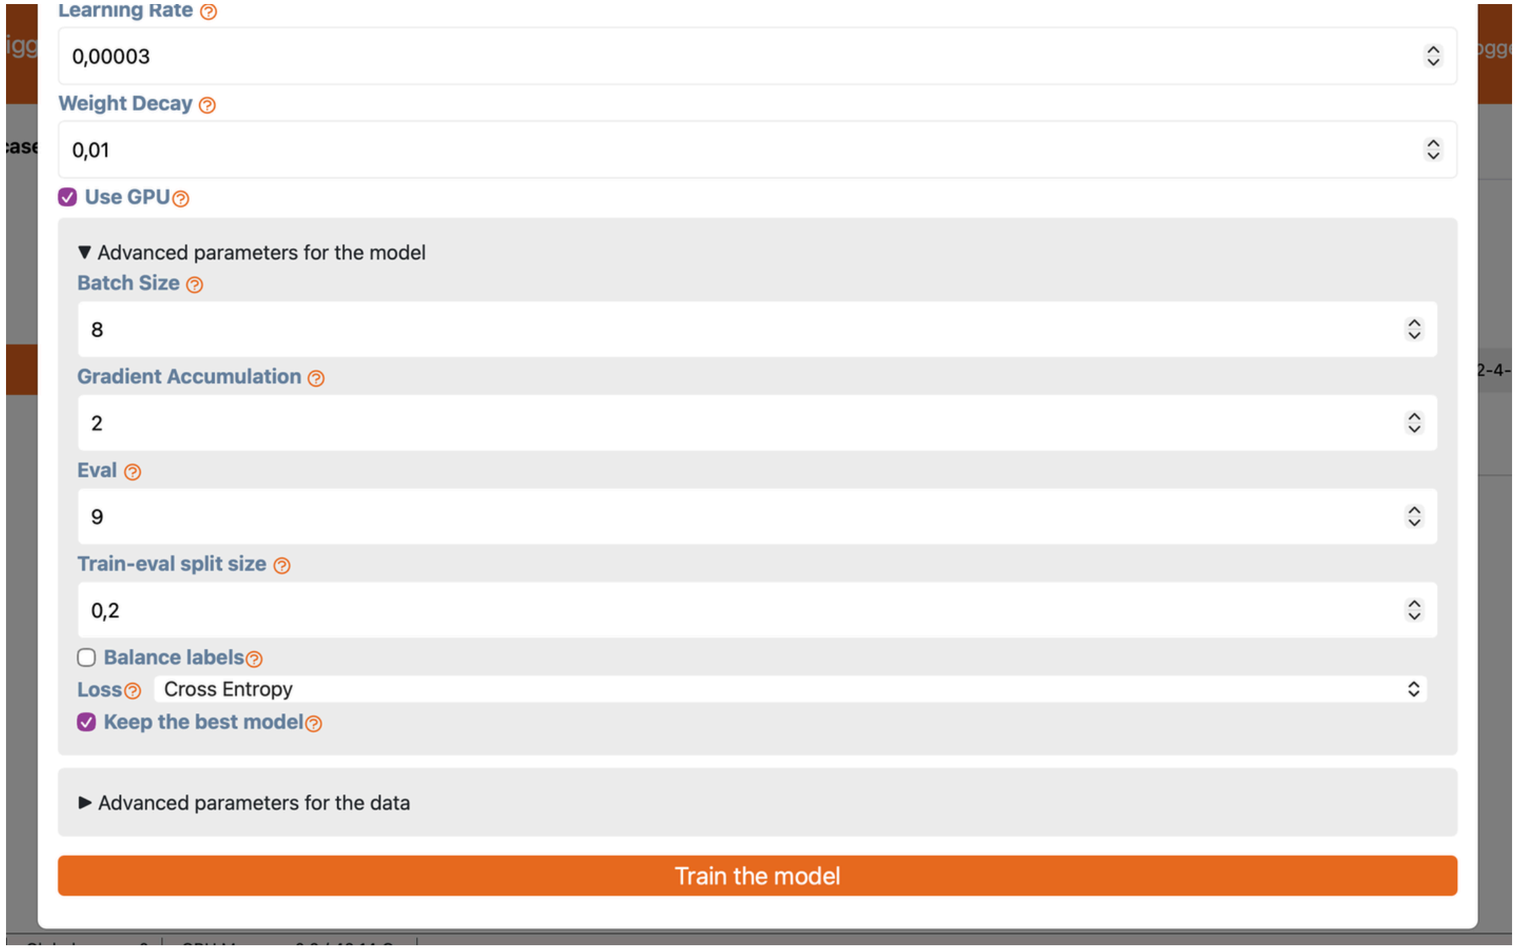
- Francophones
- Fenêtre de contexte de +1024 tokens
- Données d’entraînement conviennent

Étape 4 : entraîner des modèles

Augmenter

- Batch Size*
- Gradient Accumulation**

car 1024 tokens par texte.



*Batch Size = nombre d'exemples que le modèle traite à la fois (en mémoire).

**Gradient Accumulation = nombre de batch additionnés pour modifier les poids.

Étape 4 : entraîner des modèles

Modèle A

CamembertaV2base
1024 tokens
8 batch size
2 gradient acc
4 époques

Macro F1 score on Train-Eval set : **0.922**

Truth \ Predicted	source	non-source	Total
source	33	2	35
non-source	6	79	85
Total	39	81	120

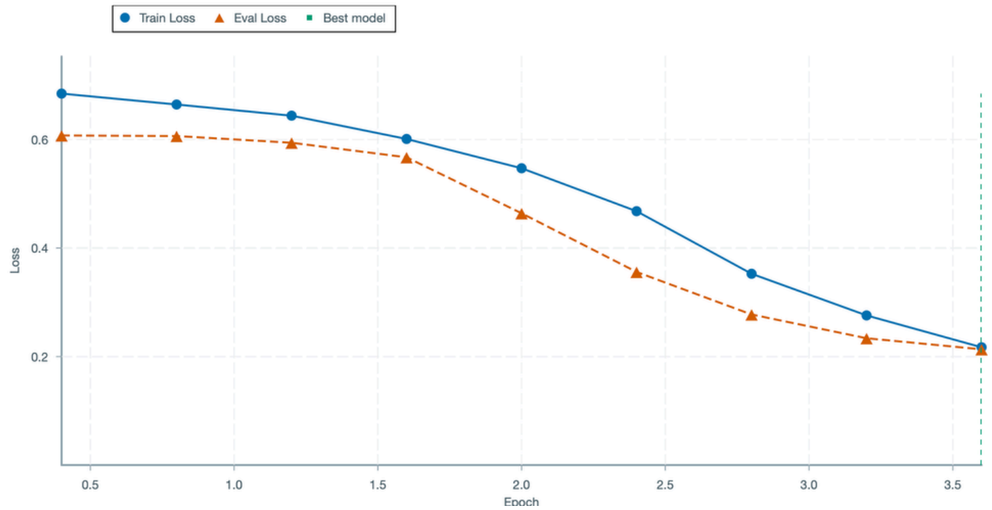
	Recall	Precision	F1
source	0.943	0.846	0.892
non-source	0.929	0.975	0.952

Vérifier que l'erreur ne provient pas d'une erreur d'annotation →

Show wrong predictions | Download as JSON | Parameters | Rename

Bons choix, mais il semblerait que le modèle pourrait encore apprendre.

=> Augmenter le nombre d'époques.



Étape 4 : entraîner des modèles

Modèle B

CamembertaV2base
1024 tokens
8 batch size
2 gradient acc
6 époques

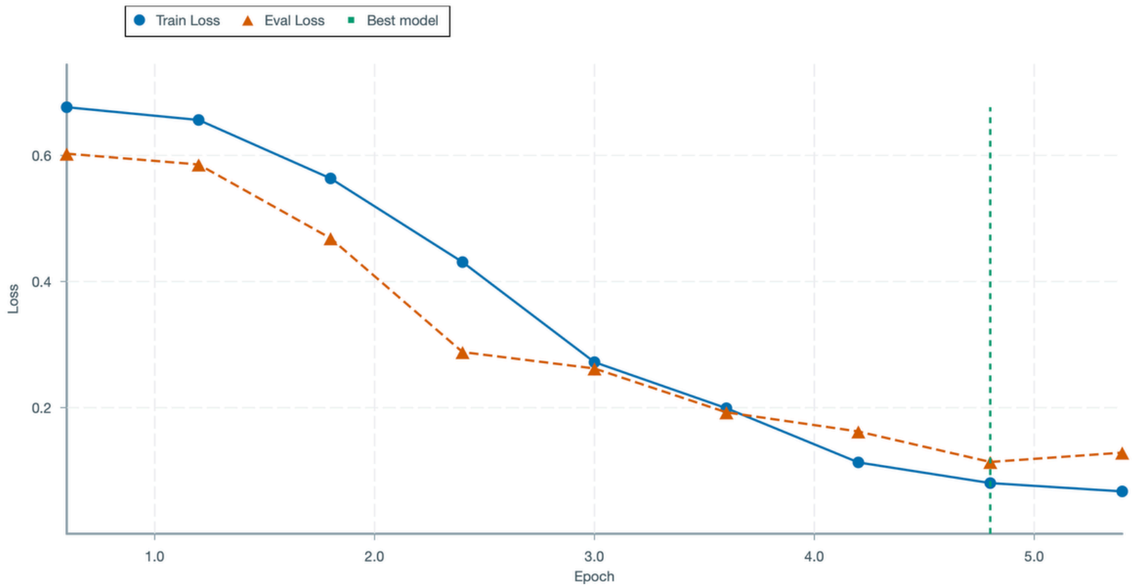
Macro F1 score on Train-Eval set : **0.96**

		Predicted		
		source	non-source	Total
Truth	source	34	1	35
	non-source	3	82	85
	Total	37	83	120

	Recall	Precision	F1
source	0.971	0.919	0.944
non-source	0.965	0.988	0.976

Show wrong predictions | Download as JSON | Parameters | Rename

Il a effectivement davantage appris.

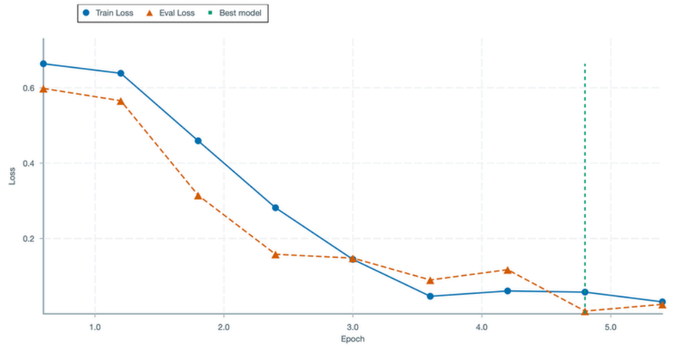


Étape 4 : entraîner des modèles

On peut essayer quelques autres modèles.

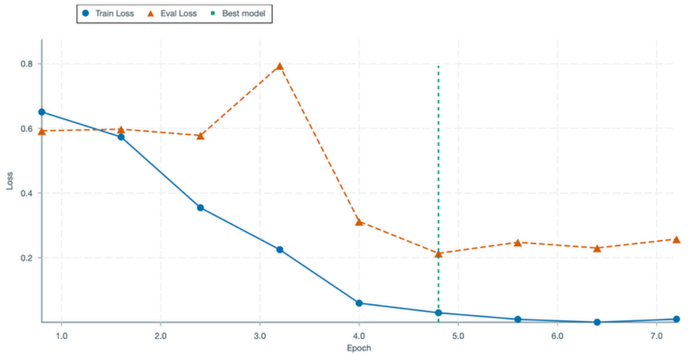
Modèle C

CamembertaV2base
1024 tokens
8 batch size
1 gradient acc
5 époques



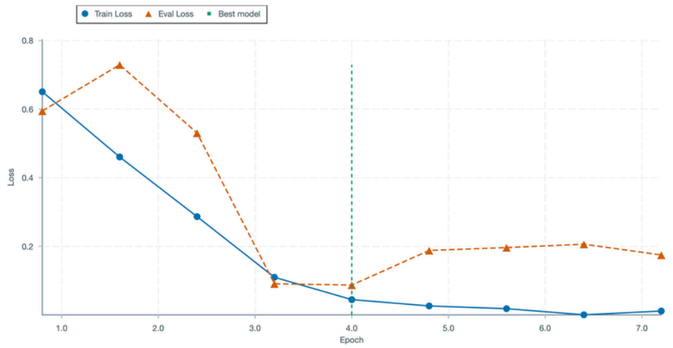
Modèle D

ModernCamemBERTbase
1024 tokens
8 batch size
2 gradient acc
8 époques



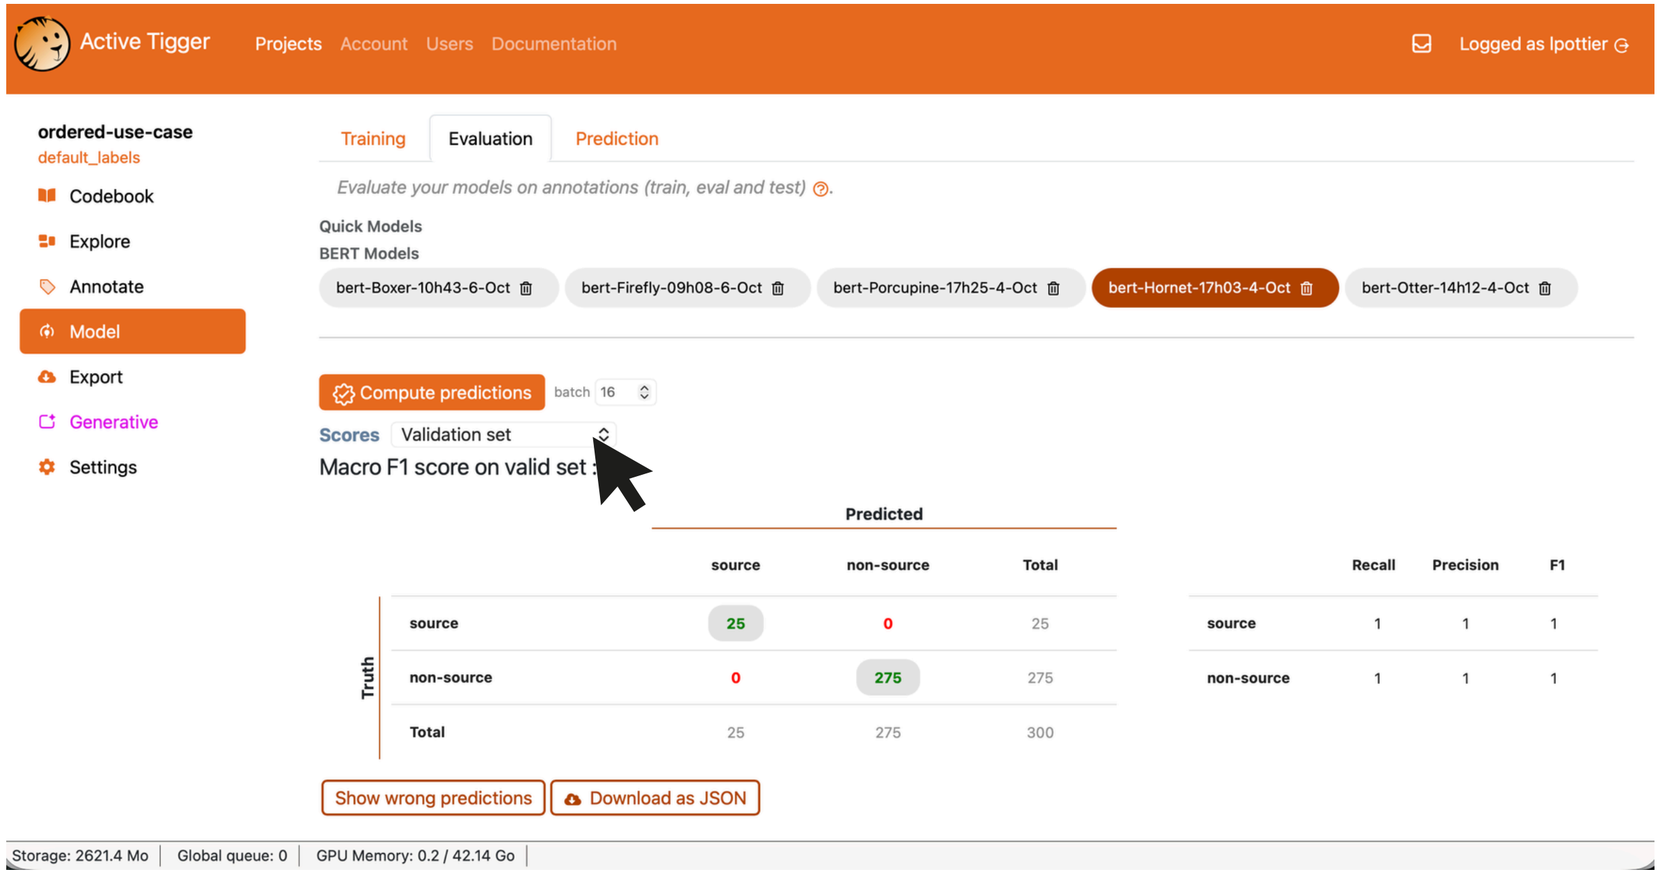
Modèle E

ModernCamemBERTbase
1024 tokens
8 batch size
1 gradient acc
8 époques



Étape 5 : sélectionner un modèle

Comparer les scores sur le set de validation.



Étape 5 : sélectionner un modèle

Modèle A Macro F1 score on valid set : **0.965**

	Recall	Precision	F1
source	0.88	1	0.936
non-source	1	0.989	0.995

Modèle B Macro F1 score on valid set : **1**

	Recall	Precision	F1
source	1	1	1
non-source	1	1	1

Modèle C Macro F1 score on valid set : **0.979**

	Recall	Precision	F1
source	1	0.926	0.962
non-source	0.993	1	0.996

Modèle D Macro F1 score on valid set : **0.959**

	Recall	Precision	F1
source	1	0.862	0.926
non-source	0.985	1	0.993

Modèle E Macro F1 score on valid set : **0.959**

	Recall	Precision	F1
source	1	0.862	0.926
non-source	0.985	1	0.993

Étape 5 : sélectionner un modèle

Modèle A Macro F1 score on valid set : **0.965**

	Recall	Precision	F1
source	0.88	1	0.936
non-source	1	0.989	0.995

Modèle B Macro F1 score on valid set : **1**

	Recall	Precision	F1
source	1	1	1
non-source	1	1	1

Modèle C Macro F1 score on valid set : **0.979**

	Recall	Precision	F1
source	1	0.926	0.962
non-source	0.993	1	0.996

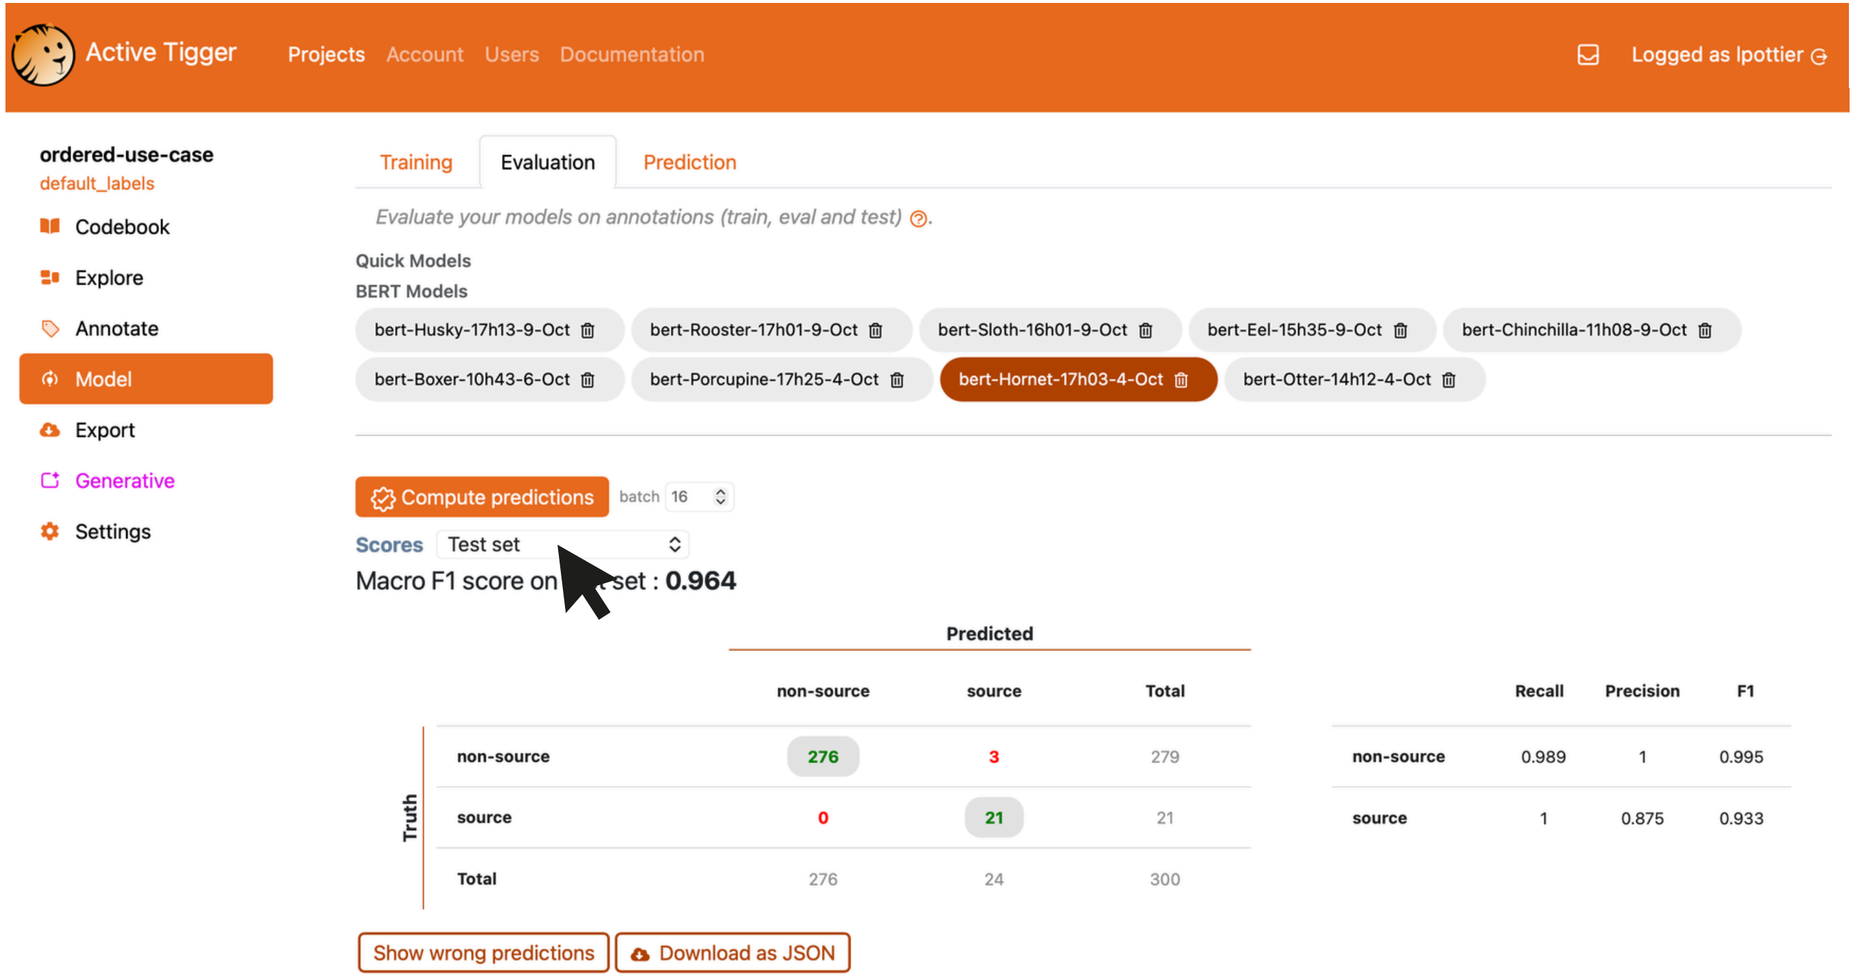
Modèle D Macro F1 score on valid set : **0.959**

	Recall	Precision	F1
source	1	0.862	0.926
non-source	0.985	1	0.993

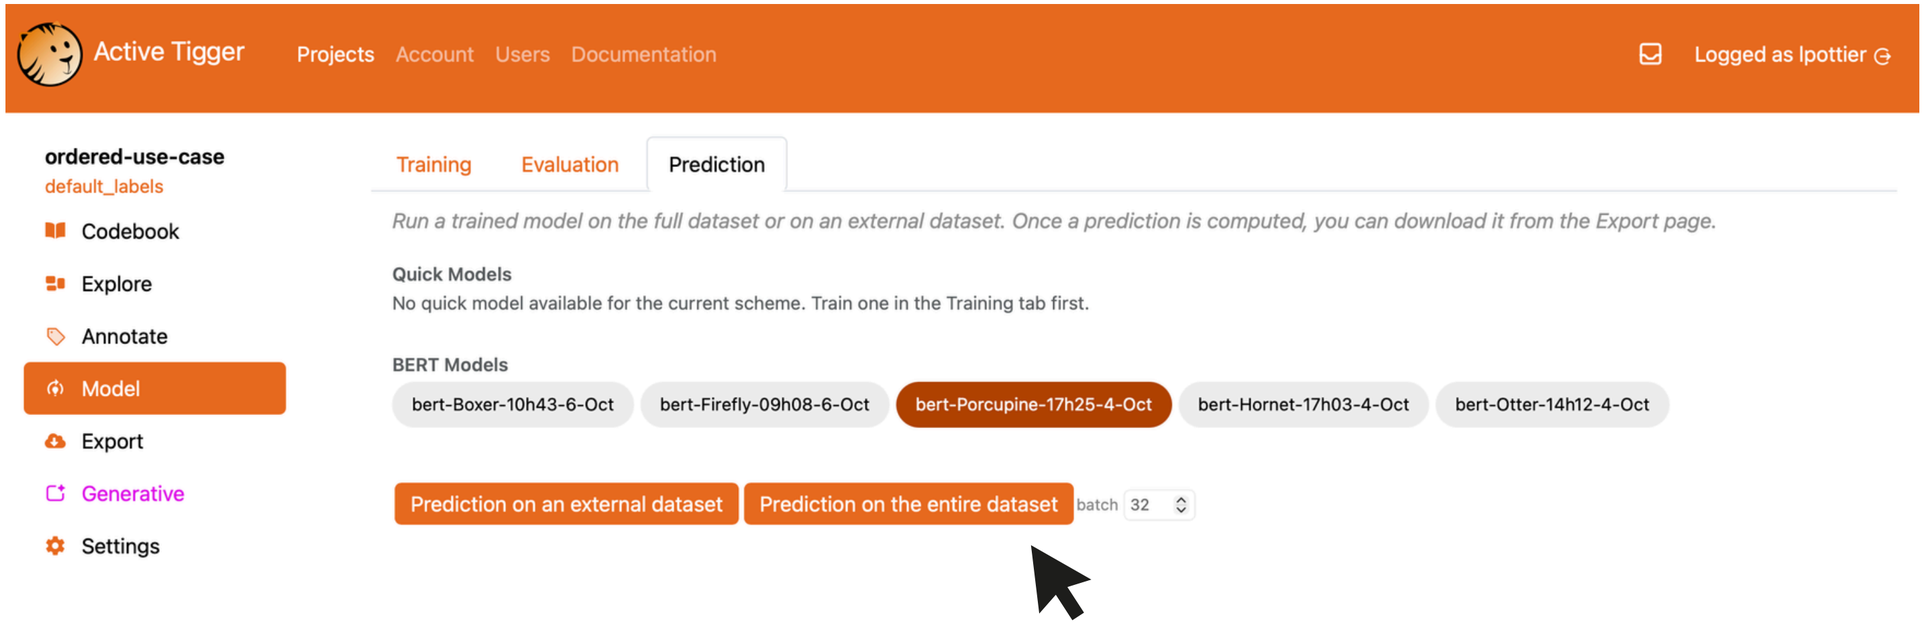
Modèle E Macro F1 score on valid set : **0.959**

	Recall	Precision	F1
source	1	0.862	0.926
non-source	0.985	1	0.993

Étape 6 : évaluer le modèle



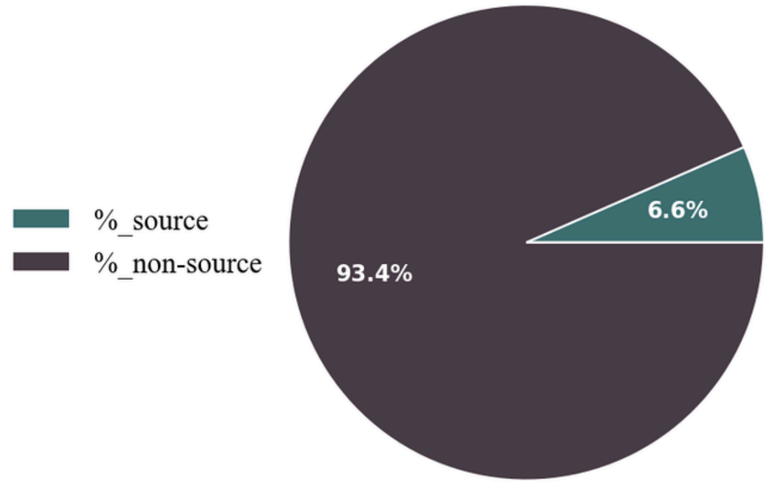
Étape 7 : étendre les prédictions



Résultats

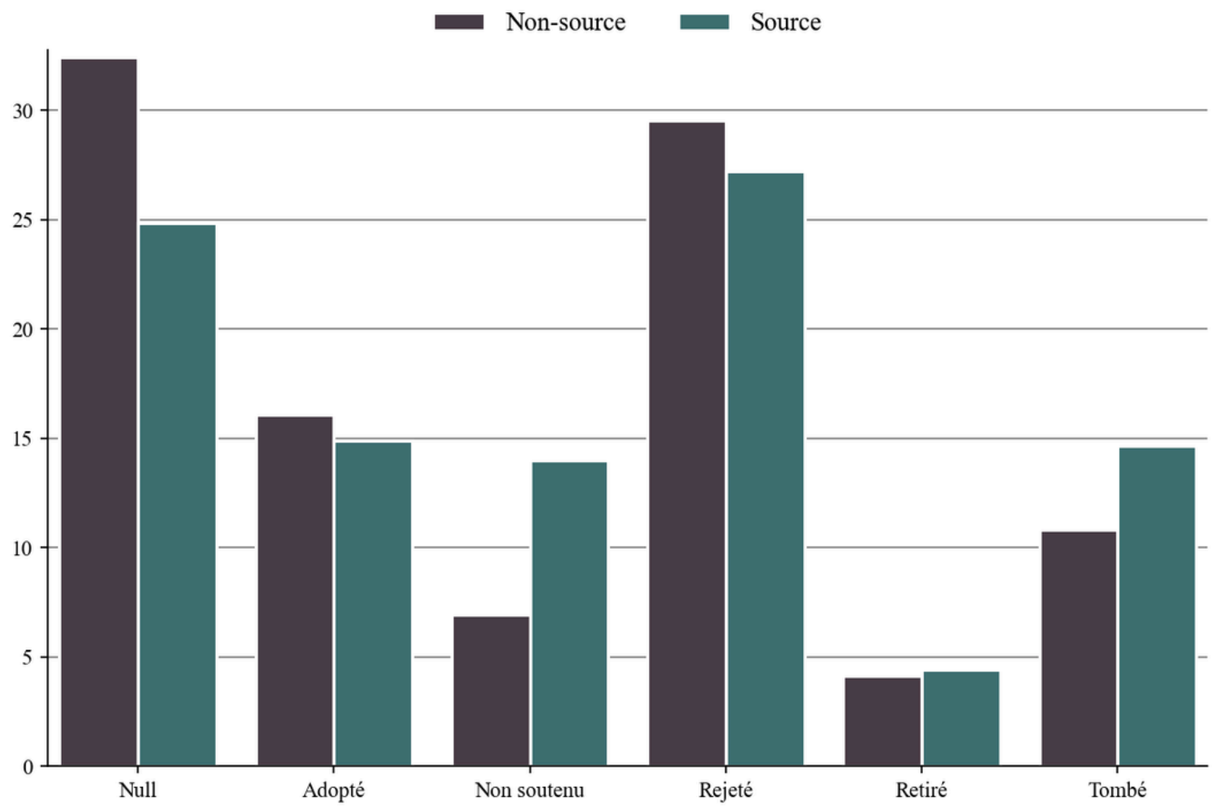
(RQ1) : Pratique minoritaire mais non marginale.

Répartition des amendements de la XVIIème législature* selon leur sourcing (en %)



*à l'exclusion des amendements dont l'exposé sommaire est null ou d'une longueur >1024 tokens.

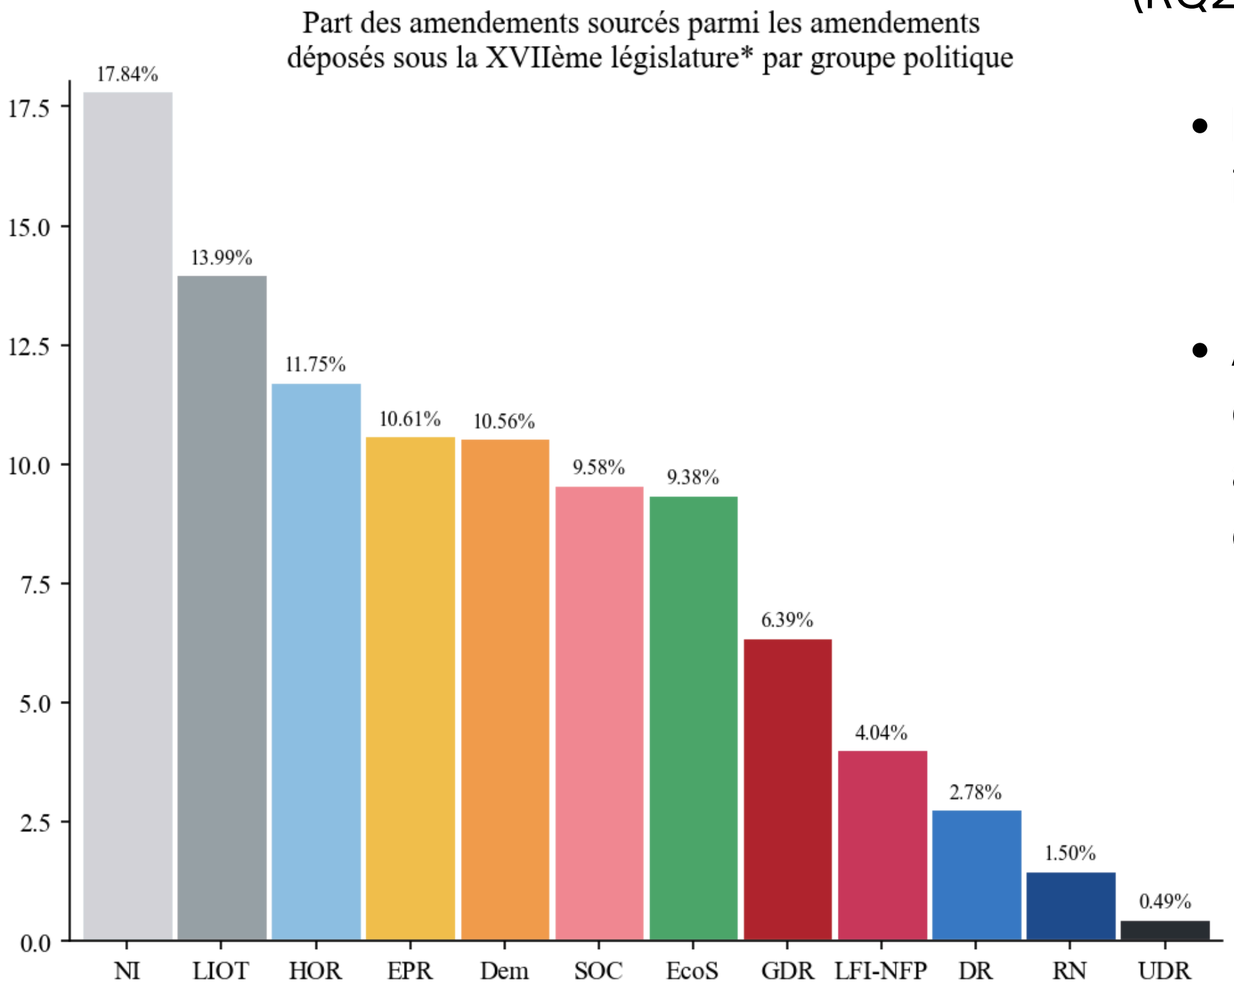
Sort des amendements de la XVIIème législature* selon leur nature (en %)



*à l'exclusion des amendements dont l'exposé sommaire est null ou d'une longueur >1024 tokens.

(RQ3) : Les amendements "source" ne sont pas davantage adoptés que les "non-source".

Résultats

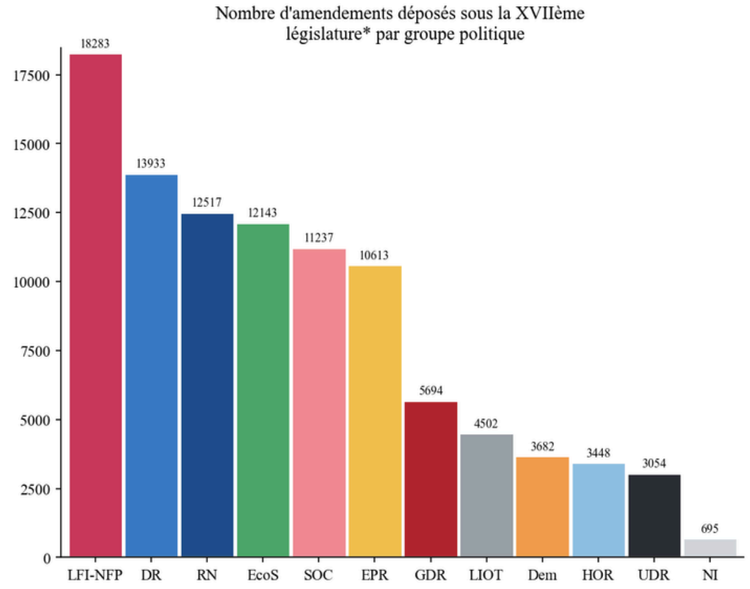


*à l'exclusion des amendements dont l'exposé sommaire est null ou d'une longueur >1024 tokens.

(RQ2) : Différence substantielle entre groupes politiques.

- Les NI et LIOT sont-ils plus soumis à influence ou plus transparents ?

- À mettre au regard du volume des amendements déposés



Intérêt, limites

Est-ce qu'un decoder (Claude, ChatGPT) aurait pu le faire ?

Si le codebook est déjà optimal, oui.

MAIS mettre en perspective la nature de notre cas :

- Codebook amélioré : **Augmentation** de la chercheuse ou du chercheur
- **Simplicité de la tâche** (peu d'appréciation subjective)
- **Absence de sensibilité des données**
- **Coût temporel limité** (peu d'annotations)

À cela s'ajoutent :

- **Coûts économique, environnemental**
- **Réplicabilité**

Intérêt, limites

Ce qu’on aurait pu ajouter ou faire différemment :

- **Exploration préalable** des données via les outils intégrés dans ActiveTigger
- **Plus d’annotations** :
  - validation et test sets (meilleur F1)
  - train set pour la catégorie “source”
- **Annotation croisée** d’une partie des données (interannotator agreement score)
- **Annotation manuelle** des 664 données de +1024 tokens retirées du dataset.



Merci !

Demande de compte, documentation, lien GitHub, lien Discord :
https://activetigger.com